




FIAP

RELATÓRIO TÉCNICO



Alexandre Natã Vicente
Antônio Cláudio Almeida
Cyd Ferreira Rodrigues
David Catherink
Marcelo Macedo Klotz

POSTECH — INTELIGÊNCIA ARTIFICIAL PARA DEVS

FASE 3 — TECH CHALLENGE

Assistente Virtual Especializado em Saúde da Mulher

com Fine-tuning LoRA · RAG/FAISS · LangChain · LangGraph

SUMÁRIO

1. Contexto e Objetivos do Trabalho	5
1.1 Grupo de trabalho.....	5
1.2 Links relacionados.....	5
1.3 Componentes utilizados	6
2. Visão Geral da Arquitetura	7
3. Dataset — PubMedQA e Dados Sintéticos	8
3.1 O que é o PubMedQA (ori_pqal.json)	8
3.2 Filtro de Relevância — Como o Código Seleciona Registros.....	8
3.3 Mapeamento de Categorias	9
3.4 Dataset Sintético (10 registros manuais)	10
4. Célula 1 — Instalação de Dependências.....	11
4.1 Por que a ordem de instalação importa?	11
4.2 Tabela de Dependências — O que é cada biblioteca e por que foi escolhida.....	11
5. Célula 2 — Imports e Configuração Geral.....	13
5.1 Sistema de Logging para Auditoria	13
5.2 Semente Aleatória (SEED = 42)	13
5.3 TypedDict para Tipagem dos Estados	13
6. Célula 3 — Carregamento e Filtro do PubMedQA.....	14
6.1 Download Direto do GitHub	14
6.2 Pipeline de Transformação dos Registros	14
6.3 Mecanismo de Fallback.....	14
7. Célula 4 — Dataset Sintético de Saúde da Mulher.....	15
7.1 Por que dados sintéticos em saúde?	15
7.2 Estrutura de cada registro sintético.....	15
8. Célula 5 — Pré-processamento e Anonimização	16
8.1 Anonimização com Expressões Regulares.....	16
8.2 Normalização Terminológica	16
8.3 Template Alpaca para Fine-tuning	17
8.4 Hash de Anonimização e Timestamp	17
9. Célula 6 — Fine-tuning com PEFT/LoRA	18
9.1 O que é Fine-tuning e por que é necessário?	18
9.2 Por que LoRA (Low-Rank Adaptation)?	18
9.3 Parâmetros LoRA utilizados e suas justificativas	18
9.4 Otimizações implementadas (e por que foram necessárias).....	19

9.5 Modelo Base: por que GPT-2?	19
10. Célula 6b — Avaliação Quantitativa (ROUGE + Bias)	20
10.1 Métricas ROUGE	20
10.2 Cobertura de Termos Médicos	20
10.3 Análise de Bias e Equidade Demográfica	20
11. Célula 7 — Base de Conhecimento Vetorial com FAISS (RAG)	22
11.1 O que é RAG e por que é superior ao fine-tuning sozinho?	22
11.2 Documentos de Protocolo incluídos na base	22
11.3 Modelo de Embeddings: paraphrase-multilingual-MiniLM-L12-v2	22
11.4 Como o FAISS funciona	23
12. Célula 8 — Assistente Médico com LangChain	24
12.1 Arquitetura do Assistente — fluxo de uma consulta	24
12.2 Configuração do LLM Local	24
12.3 Template de Prompt Especializado	25
12.4 Detecção de Sensibilidade	25
12.5 Validação de Respostas	25
13. Célula 9 — Fluxos de Triagem com LangGraph	26
13.1 Estado Compartilhado — EstadoPaciente	26
13.2 Fluxo 1 — Triagem Ginecológica	27
13.3 Fluxo 2 — Detecção de Violência Doméstica	27
13.4 Fluxo 3 — Avaliação Obstétrica	27
13.5 Fluxo 4 — Prevenção e Acompanhamento (com aresta condicional)	28
14. Segurança, Validação e Auditoria	29
14.1 Limites de Atuação — Hard Rules	29
14.2 Logging e Auditoria	29
14.3 Explainability	29
15. Integração Completa — Como os Componentes se Conectam	31
15.1 Dois modos de operação do sistema	31
15.2 Fluxo de dados ponta a ponta	31
16. Considerações Éticas e Regulatórias	33
16.1 LGPD — Lei Geral de Proteção de Dados	33
16.2 Assistente como Ferramenta de Apoio, não Substituto	33
16.3 Sensibilidade Cultural e Equidade	33
16.4 Protocolo específico para violência doméstica	33

1. CONTEXTO E OBJETIVOS DO TRABALHO

Este documento explica de forma completa e acessível o trabalho de conclusão da Fase 3 da pós-graduação em Inteligência Artificial para DEVs da POSTECH. O trabalho consiste na construção de um protótipo de assistente virtual médico especializado em saúde da mulher, utilizando quatro tecnologias centrais de Inteligência Artificial moderna, a partir do desafio, disponibilizado no repositório do Github para referência ([PDF](#)).

Sobre o desafio proposto

Redes hospitalares especializadas em saúde feminina necessitam de apoio computacional para triagem clínica, identificação de situações de risco (como violência doméstica), acompanhamento obstétrico e ações de prevenção. O assistente criado neste trabalho automatiza esses fluxos, sempre com validação humana obrigatória.

1.1 Grupo de trabalho

O grupo responsável por este desafio foi composto pelos seguintes integrantes da Secretaria de Segurança Pública do Distrito Federal (SSP/DF):

- **Alexandre Natã Vicente** (rm370024) (ale.n.vicente@gmail.com)
- **Antônio Cláudio Almeida** (rm370052) (antonioalmeida@gmail.com)
- **Cyd Ferreira Rodrigues** (rm370004) (cydnelson@gmail.com)
- **David Catherinck** (rm369997) (d.catherinck@gmail.com)
- **Marcelo Macedo Klotz** (rm370010) (marceloklotz@gmail.com)

1.2 Links relacionados

Os arquivos relacionados a este desafio podem ser acessados por meio dos seguintes endereços eletrônicos:

- **Repositório do Github:**
<https://github.com/marceloklotz/fiap-terceira-fase-ssp-df/>
- **Notebook:**
https://github.com/marceloklotz/fiap-terceira-fase-ssp-df/blob/main/FIAP_Fase_3.ipynb
- **Vídeo explicativo:**
<https://www.youtube.com/watch?v=F-G5JFNiwdE>
- **Base de dados (link original):**
https://raw.githubusercontent.com/pubmedqa/pubmedqa/refs/heads/master/data/ori_pqal.json

1.3 Componentes utilizados

O trabalho entrega quatro componentes integrados, conforme requisitos do desafio proposto:

Componente	Descrição e Tecnologia
Fine-tuning LoRA	Ajuste fino do modelo GPT-2 com a técnica LoRA, usando dados biomédicos reais (PubMedQA) e sintéticos baseados em diretrizes brasileiras (FEBRASGO, INCA, OMS).
RAG + FAISS	Base de conhecimento vetorial com 6 protocolos clínicos e registros do PubMedQA. Busca semântica em milissegundos via FAISS, integrada ao LangChain.
LangChain	Pipeline de integração entre o modelo fine-tuned, a base vetorial e as regras de segurança. Classe AssistenteMedicoFeminino com validação, logging e explainability.
LangGraph	Quatro grafos de estado orquestrando fluxos clínicos: Triage Ginecológica, Detecção de Violência Doméstica, Avaliação Obstétrica e Prevenção.

2. VISÃO GERAL DA ARQUITETURA

A arquitetura do trabalho é modular e em camadas. Cada camada tem uma responsabilidade específica e se comunica com as demais por interfaces bem definidas. O diagrama abaixo representa o fluxo completo de dados e decisões:

ENTRADA DE DADOS PubMedQA (1.000 artigos biomédicos) + 10 registros sintéticos FEBRASGO/INCA/OMS
ETAPA 1 — PRÉ-PROCESSAMENTO Anonimização (LGPD) → Normalização terminológica → Formatação template Alpaca
ETAPA 2 — FINE-TUNING LoRA GPT-2 + adaptadores LoRA (r=8, alpha=32) → modelo especializado em saúde feminina → salvo em disco
ETAPA 3 — BASE VETORIAL RAG Embeddings multilíngues (MiniLM) → índice FAISS → busca semântica k=3
ETAPA 4 — ASSISTENTE LANGCHAIN LLM fine-tuned + Retriever FAISS + Prompt especializado + Validação segurança + Logging auditoria
ETAPA 5 — FLUXOS LANGGRAPH 4 grafos de estado: Triage Ginecológica / Violência Doméstica / Obstétrico / Prevenção
SAÍDA ESTRUTURADA Resposta + Fontes citáveis + Nível de confiança + Validação segurança + Log auditoria

3. DATASET — PUBMEDQA E DADOS SINTÉTICOS

3.1 O que é o PubMedQA (ori_pqal.json)

O PubMedQA é um benchmark biomédico amplamente reconhecido na comunidade científica. Ele contém **1.000 perguntas clínicas extraídas de artigos publicados no PubMed** (base de dados de literatura médica da Biblioteca Nacional de Medicina dos EUA). Cada registro no arquivo JSON possui:

Campo no JSON	Significado e Uso no Trabalho
QUESTION	A pergunta clínica original do artigo. Usada como 'instrucao' no template de fine-tuning.
CONTEXTS	Lista de parágrafos dos abstracts dos artigos que embasam a resposta. Usado como contexto bruto na base vetorial RAG.
LONG_ANSWER	Resposta longa derivada do artigo. Usada como 'resposta' no par instrução-resposta para fine-tuning.
MESHES	Termos MeSH (Medical Subject Headings) — vocabulário controlado da medicina. Usado para inferir a categoria temática do registro.
final_decision	Decisão do artigo: 'yes', 'maybe' ou 'no'. Convertida em nível de confiança numérico: yes=0.90, maybe=0.72, no=0.55.
YEAR	Ano de publicação do artigo. Relevante para rastreabilidade e atualidade das informações.

Por que o PubMedQA foi escolhido?

O desafio exige que o fine-tuning seja realizado com 'dados específicos da área'. O PubMedQA fornece literatura biomédica revisada por pares, com fonte citável (PMID) — atendendo ao critério de “*explainability*”. Aproximadamente 27% dos registros cobrem temas de saúde feminina diretamente relevantes (ginecologia, obstetrícia, contracepção, câncer de mama, violência, saúde mental materna). O *download* é feito diretamente do GitHub oficial do projeto, sem necessidade de Google Drive.

3.2 Filtro de Relevância — Como o Código Seleciona Registros

Nem todos os 1.000 registros do PubMedQA são relevantes para saúde da mulher. O código implementa um filtro por palavras-chave que verifica se o campo QUESTION, LONG_ANSWER ou MESHES contém termos como: *gynecol, obstetric, pregnan, menstrual, breast cancer, domestic violence, contraceptiv, menopause, prenatal, postpartum, reproduct, cervical, uterine, ovarian, maternal, endometri, mammograph, female, woman, women, gender, fertility, eclampsia, placenta, lactation, breastfeed*

O resultado é um subconjunto de registros biomédicos com alta relevância para o domínio do trabalho, que foram então convertidos para o formato interno do projeto (campos: instrucao, resposta, categoria, fonte, nivel_confianca).

3.3 Mapeamento de Categorias

Cada registro filtrado recebe uma categoria temática inferida automaticamente a partir dos campos QUESTION e MESHES. O mapeamento é:

Palavra-chave no texto	Categoria inferida
breast, mammograph	rastreamento_mama
cervical	prevencao
uterine, ovarian, endometri, menstrual	ginecologia
pregnan, obstetric, prenatal, maternal	obstetricia
postpartum	saude_mental_materna
contraceptiv	contracepcao
menopause	climaterio
reproduct, lactation, breastfeed	saude_reprodutiva
violence	violencia_domestica
(nenhuma correspondência)	medicina_geral

3.4 Dataset Sintético (10 registros manuais)

Além do PubMedQA, o trabalho inclui 10 registros criados manualmente em português, baseados em diretrizes brasileiras e internacionais. Esses registros cobrem os temas mais sensíveis e relevantes do atendimento à saúde feminina no Brasil:

Tema	Fonte de Referência
Irregularidade menstrual e SOP	FEBRASGO — Distúrbios Menstruais 2023
Sintomas e diagnóstico de endometriose	FEBRASGO — Endometriose 2022
Efeitos colaterais dos anticoncepcionais orais	ANVISA + FEBRASGO 2023
Sinais de alerta na gestação (pré-eclâmpsia)	OMS / FEBRASGO Emergências Obstétricas 2023
Identificação de depressão pós-parto	DSM-5 / Escala Edinburgh / Protocolo MS Brasil
Protocolo de violência doméstica (SINAN)	Ministério da Saúde / Lei Maria da Penha
Periodicidade do Papanicolau	INCA — Diretrizes Rastreamento 2023
Rastreamento de câncer de mama	INCA + American Cancer Society
Manejo do climatério e menopausa	FEBRASGO — Consenso Climatério 2023
Ansiedade severa em mulheres	Protocolo MS — Saúde Mental na APS / DSM-5

Nota importante sobre os dados sintéticos

Os registros sintéticos são inspirados em diretrizes nacionais e internacionais, **mas não reproduzem integralmente nenhum protocolo oficial**. Em um sistema real, a base de dados deve ser construída diretamente a partir de protocolos institucionais validados, devidamente versionados e com revisão especializada.

4. CÉLULA 1 — INSTALAÇÃO DE DEPENDÊNCIAS

A primeira célula do notebook instala e verifica todas as bibliotecas necessárias. A ordem de instalação é deliberada e tecnicamente importante — não é aleatória.

4.1 Por que a ordem de instalação importa?

O ecossistema LangChain/LangGraph possui dependências interdependentes. **Instalar fora de ordem ou com versões conflitantes gera erros difíceis de diagnosticar.** Por isso o código:

- Passo 1 — Desinstala instalações anteriores conflitantes (langchain, langgraph etc.)
- Passo 2 — Instala numpy com versão controlada (2.0–2.5), necessário para compatibilidade com FAISS e PyTorch
- Passo 3 — Instala o ecossistema LangChain completo com versões mínimas definidas
- Passo 4 — Instala langgraph separadamente (orquestrador de fluxos)
- Passo 5 — Instala bibliotecas de ML: transformers, datasets, peft, trl, accelerate, bitsandbytes
- Passo 6 — Instala ferramentas vetoriais: sentence-transformers e faiss-cpu
- Passo 7 — Instala utilitários: ijson, cryptography, rouge_score, evaluate

4.2 Tabela de Dependências — O que é cada biblioteca e por que foi escolhida

Biblioteca / Versão mínima	Função no projeto e justificativa da escolha
langchain >= 1.0.0	Framework de orquestração de LLMs. Permite encadear LLM + retriever + prompt em um único pipeline (RetrievalQA).
langchain-core >= 1.3.3	Núcleo do LangChain: define interfaces, PromptTemplate, Document e componentes base usados em todo o projeto.
langchain-community >= 0.4.1	Integrações com ferramentas externas. Contém o FAISS como VectorStore.
langchain-huggingface >= 1.2.2	Integração do LangChain com modelos Hugging Face (HuggingFacePipeline, HuggingFaceEmbeddings).
langchain-classic	Versão estável de chains clássicas como RetrievalQA, necessária para a classe do assistente.
langgraph >= 1.1.9	Orquestrador de grafos de estado. Permite criar os 4 fluxos clínicos com nodos, arestas e estado compartilhado.
transformers >= 4.40.0	Biblioteca Hugging Face para carregar, tokenizar e gerar texto com modelos de linguagem (GPT-2, LLaMA, Falcon).
peft >= 0.10.0	Parameter-Efficient Fine-Tuning — implementa LoRA, QLoRA e outros métodos de ajuste fino eficiente de LLMs.

Biblioteca / Versão mínima	Função no projeto e justificativa da escolha
trl >= 0.8.0	Transformer Reinforcement Learning — facilita fine-tuning supervisionado com SFTTrainer e outros treinadores.
datasets >= 2.18.0	Manipulação eficiente de datasets no formato Hugging Face, com suporte a tokenização em lote e splits automáticos.
accelerate >= 0.27.0	Abstração de hardware para treinamento em CPU, GPU única ou múltiplas GPUs sem alterações no código.
bitsandbytes >= 0.43.0	Quantização de modelos em 4-bit/8-bit. Reduz uso de VRAM para fine-tuning de modelos grandes em GPUs menores.
sentence-transformers >= 2.7.0	Gera embeddings semânticos de frases para alimentar o índice FAISS. Modelo multilíngue MiniLM usado no projeto.
faiss-cpu >= 1.8.0	Facebook AI Similarity Search — busca vetorial por similaridade semântica em milissegundos, mesmo com milhares de documentos.
rouge_score + evaluate	Métricas ROUGE-1/2/L para avaliação quantitativa da qualidade das respostas geradas pelo modelo.
ijson	Parser JSON incremental — lê o arquivo JSON de 1.000 registros do PubMedQA sem carregar tudo na memória de uma vez.
torchao >= 0.16.0	Otimizações de memória e velocidade para PyTorch, especialmente útil no Colab com GPU T4.

5. CÉLULA 2 — IMPORTS E CONFIGURAÇÃO GERAL

Esta célula realiza a configuração fundamental do ambiente de execução. Três aspectos merecem atenção especial:

5.1 Sistema de Logging para Auditoria

Trata-se de requisito contido na seção 'Logging e auditoria especializados' do desafio, que foi configurado no código, conforme abaixo:

- Nível INFO como padrão — registra todas as interações normais
- Formato estruturado: data/hora | nível | mensagem — permite filtrar logs por período ou severidade
- Dois handlers simultâneos: StreamHandler (terminal) e FileHandler (arquivo auditoria_assistente.log)
- Nome específico 'AssistenteMedicoFeminino' — identifica o logger nas aplicações com múltiplos módulos

Por que registrar em arquivo E no terminal?

O StreamHandler permite monitorar a execução em tempo real durante o desenvolvimento e demonstrações. O FileHandler persiste os logs em disco, permitindo auditoria posterior de todas as interações — fundamental em aplicações de saúde onde a rastreabilidade é exigência regulatória (LGPD, normas do CFM).

5.2 Semente Aleatória (SEED = 42)

A linha `random.seed(42)` e `np.random.seed(42)` garante reprodutibilidade dos experimentos. Isso significa que se o notebook for executado duas vezes com os mesmos dados, os resultados serão idênticos — essencial para comparar versões do modelo e para validação científica dos resultados.

5.3 TypedDict para Tipagem dos Estados

A importação de TypedDict do módulo typing é usada nas células do LangGraph para definir a estrutura do EstadoPaciente — o dicionário tipado que representa a 'ficha de atendimento' que percorre cada nodo dos grafos de triagem.

6. CÉLULA 3 — CARREGAMENTO E FILTRO DO PUBMEDQA

Esta célula realiza o download automático do dataset PubMedQA do GitHub oficial, filtra os registros relevantes para saúde feminina e os transforma no formato interno do projeto.

6.1 Download Direto do GitHub

O código usa `urllib.request.urlopen` para baixar o arquivo JSON diretamente da URL pública do repositório oficial do PubMedQA no GitHub. Isso elimina a dependência do Google Drive, tornando o notebook mais portátil e reproduzível em qualquer ambiente.

6.2 Pipeline de Transformação dos Registros

A função `converter_registro` transforma cada registro do formato original do PubMedQA para o formato interno do projeto. O mapeamento é:

Campo PubMedQA original	Campo interno gerado
PMID (chave do dict)	<code>fonte = 'PubMed PMID:XXXXX MeSH1, MeSH2, MeSH3'</code>
QUESTION	<code>instrucao</code> (a pergunta a ser respondida pelo modelo)
LONG_ANSWER	<code>resposta</code> (resposta baseada em evidências)
CONTEXTS (lista de parágrafos)	<code>contextos_raw</code> (texto bruto para enriquecer a base vetorial)
final_decision (yes/maybe/no)	<code>nivel_confianca</code> (0.90 / 0.72 / 0.55)
MESHES + QUESTION (combinados)	<code>categoria</code> (inferida por palavras-chave)

6.3 Mecanismo de Fallback

O bloco `try/except` garante que, se o download do PubMedQA falhar (por problemas de rede, timeout ou outros), o notebook continua sua execução usando apenas o dataset sintético da Célula 4. Isso torna o trabalho robusto mesmo em ambientes com conectividade limitada.

7. CÉLULA 4 — DATASET SINTÉTICO DE SAÚDE DA MULHER

O dataset sintético serve a dois propósitos complementares: (1) garantir cobertura de temas clinicamente críticos em português (o PubMedQA é majoritariamente em inglês); e (2) fornecer dados de treinamento baseados nas diretrizes brasileiras (FEBRASGO, INCA, Ministério da Saúde) que são as referências aplicáveis no contexto hospitalar nacional.

7.1 Por que dados sintéticos em saúde?

Dados reais de pacientes são protegidos pela LGPD (Lei Geral de Proteção de Dados) e por normas do CFM (Conselho Federal de Medicina). Em um protótipo acadêmico é inviável usar prontuários reais. Dados sintéticos — gerados manualmente por especialistas ou com auxílio de IA, mas revisados — permitem desenvolver e testar pipelines sem expor informações sensíveis. Esta é prática padrão em pesquisa de IA em saúde.

7.2 Estrutura de cada registro sintético

Campo	Conteúdo e propósito
instrucao	A pergunta clínica ou situação apresentada ao assistente. Ex.: 'Quais são os sinais de alerta na gravidez?'
resposta	Orientação especializada detalhada, sempre com aviso de que não substitui consulta médica.
categoria	Tag temática: ginecologia, contracepcao, obstetricia, saude_mental_materna, violencia_domestica, prevencao, climaterio, saude_mental.
fonte	Referência à diretriz que embasou a resposta. Ex.: 'FEBRASGO 2023', 'INCA 2023', 'Lei Maria da Penha'.
nivel_confianca	Score de 0 a 1 indicando confiança estimada. Registros sintéticos têm scores entre 0.90 e 0.98, refletindo sua ancoragem em diretrizes consolidadas.

Combinação dos dois datasets

Ao final da Célula 4, o código combina os 10 registros sintéticos com todos os registros filtrados do PubMedQA em um único DataFrame `df_treino`. Este DataFrame combinado é o que alimenta todo o pipeline subsequente de pré-processamento e fine-tuning. A combinação garante cobertura bilíngue (PT/EN) e diversidade de fontes (diretrizes brasileiras + literatura biomédica internacional).

8. CÉLULA 5 — PRÉ-PROCESSAMENTO E ANONIMIZAÇÃO

A classe `PreProcessadorMedicoFeminino` implementa o pipeline de preparação dos dados para o fine-tuning. Esta etapa é fundamental por dois motivos: segurança (remoção de dados pessoais, LGPD) e qualidade do modelo (normalização terminológica e formatação adequada para fine-tuning).

8.1 Anonimização com Expressões Regulares

A anonimização detecta e substitui padrões de dados pessoais identificáveis no texto, usando expressões regulares (regex). Os padrões implementados são:

Padrão detectado	Substituição aplicada
CPF (000.000.000-00)	[CPF_ANONIMIZADO]
Data de nascimento (dd/mm/yyyy)	[DATA_NASCIMENTO]
CEP (00000-000)	[CEP]
Telefone (com ou sem DDD)	[TELEFONE]
Endereço de e-mail	[EMAIL]
Número de prontuário (ex.: 'Prontuário nº 12345')	[PRONTUARIO_ANONIMIZADO]
Sequência de 7 dígitos isolados	[ID_PACIENTE]

Esta etapa simula a conformidade com a LGPD para sistemas de saúde, onde dados de pacientes devem ser anonimizados antes de qualquer processamento por sistemas de IA.

8.2 Normalização Terminológica

A normalização converte termos leigos para terminologia médica padronizada. Isso melhora a coerência do vocabulário do dataset e aproxima os textos ao linguajar de protocolos clínicos. Exemplos:

Termo leigo (entrada)	Termo médico (saída)
remédios / remédio	medicamentos / medicamento
dor de barriga	dor abdominal
dor nas costas	lombalgia
enjoo na gravidez	emese gravídica

Termo leigo (entrada)	Termo médico (saída)
menstruação atrasada	atraso menstrual
grávida	gestante

8.3 Template Alpaca para Fine-tuning

O formato Alpaca é um padrão amplamente adotado para fine-tuning de LLMs orientados a instruções (como LLaMA, Falcon e GPT-2). Ele estrutura cada exemplo de treinamento em três seções:

```
### Instrucao:
Voce e um assistente medico especializado em saude da mulher.
Responda de forma precisa, empatica e sempre recomende avaliacao
presencial quando necessario.

{instrucao - a pergunta clínica}

### Resposta:
{resposta - a orientação especializada}
```

Este formato ensina ao modelo o padrão input→output desejado, além de estabelecer a persona do assistente logo no início. A instrução de sistema (papel do assistente) é repetida em cada exemplo para que o modelo internalize esse comportamento.

8.4 Hash de Anonimização e Timestamp

O pipeline adiciona dois campos de rastreabilidade a cada registro processado: (1) `hash_anonimizacao` — hash SHA-256 dos 12 primeiros caracteres da instrução processada, que permite verificar se um registro foi alterado sem expor seu conteúdo; e (2) `timestamp_processamento` — data/hora do processamento, essencial para auditorias de quando os dados foram preparados.

9. CÉLULA 6 — FINE-TUNING COM PEFT/LORA

Esta é a etapa central do trabalho do ponto de vista de aprendizado de máquina. O fine-tuning adapta um modelo de linguagem pré-treinado (GPT-2) para o domínio específico de saúde da mulher, sem precisar retrainar o modelo do zero.

9.1 O que é Fine-tuning e por que é necessário?

Modelos de linguagem como GPT-2, LLaMA e Falcon são pré-treinados em grandes corpora textuais genéricos (livros, artigos, internet). Eles compreendem linguagem, mas não possuem conhecimento especializado de saúde feminina nem seguem protocolos médicos específicos. O fine-tuning 'recalibra' os pesos do modelo para que ele responda de forma especializada, usando a terminologia correta, citando fontes e seguindo as regras de segurança definidas.

9.2 Por que LoRA (Low-Rank Adaptation)?

Retreinar completamente um modelo como GPT-2 (117M parâmetros) ou LLaMA (7B parâmetros) demandaria múltiplas GPUs de alto desempenho e dias de processamento. O LoRA resolve isso com uma abordagem elegante:

Como o LoRA funciona

Em vez de modificar os bilhões de parâmetros originais do modelo, o LoRA adiciona matrizes auxiliares de 'baixo posto' (low-rank) acopladas às camadas de atenção. Apenas essas matrizes são treinadas — representando menos de 1% do total de parâmetros. O resultado é um modelo especializado obtido em um menor tempo, mantendo todo o conhecimento geral do modelo base intacto.

9.3 Parâmetros LoRA utilizados e suas justificativas

Parâmetro	Valor e justificativa
r (rank)	8 — Controla a capacidade das matrizes auxiliares. $r=8$ é o padrão para domínios especializados: suficiente para especialização sem overfitting.
lora_alpha	32 — Fator de escala dos pesos LoRA. A razão $\alpha/r = 4$ é empiricamente eficaz para fine-tuning de domínio.
target_modules	['c_attn'] — Camada de atenção do GPT-2. Em modelos LLaMA usaria ['q_proj', 'v_proj']. A atenção é onde reside o 'conhecimento relacional' do modelo.
lora_dropout	0.05 — Regularização leve para evitar overfitting em datasets pequenos (<300 amostras).
task_type	CAUSAL_LM — Modelagem de linguagem causal: o modelo aprende a prever o próximo token, padrão para modelos geradores de texto.

9.4 Otimizações implementadas (e por que foram necessárias)

A versão original do código levaria aproximadamente 2 dias para executar no Google Colab. O notebook documenta explicitamente os problemas e as correções:

Problema original	Otimização aplicada — resultado
max_length=512 tokens por amostra	Reduzido para 256 — metade do compute sem perda relevante (respostas médicas cabem em ~200 palavras)
Sem limite de amostras de treino	MAX_AMOSTRAS_TREINO = 80 (10 sintéticos + 70 PubMedQA) — suficiente para demonstrar fine-tuning
batch_size=2	Aumentado para 4 com gradient_accumulation=4 — simula batch efetivo de 16 sem estourar VRAM
fp16=False (float32 sempre)	fp16 ativo somente quando há GPU (float32 em CPU) — 2x mais rápido na GPU T4 do Colab
3 épocas de treinamento	1 época — suficiente para datasets pequenos (<300 amostras); epochs adicionais causariam overfitting
Sem teto de passos	max_steps=80 — teto absoluto de segurança para evitar treino infinito em datasets grandes
save_strategy='epoch' (3 checkpoints)	save_strategy='no' — elimina I/O de checkpoints intermediários, economizando minutos
Sem agrupamento por tamanho	group_by_length=True — agrupa amostras de tamanho similar, reduz padding desnecessário
dataloader_num_workers=0	dataloader_num_workers=2 — tokenização paralela, acelera carregamento dos dados

Tempo estimado após otimizações

GPU T4 (Colab gratuito): ~5–10 minutos. CPU apenas: ~20–30 minutos. Sem as otimizações: ~2 dias.

9.5 Modelo Base: por que GPT-2?

Em um protótipo acadêmico executado no Google Colab gratuito, o GPT-2 é a escolha pragmática: é leve (117M parâmetros), público, sem restrição de licença e executa em CPU ou GPU T4 sem problemas de memória. Em produção real, o notebook deixa explícito que simplesmente substituir 'gpt2' por 'meta-llama/Llama-2-7b-hf' ou 'tiiuae/falcon-7b' no código já utilizaria um modelo mais poderoso — a arquitetura do fine-tuning não muda.

10. CÉLULA 6B — AVALIAÇÃO QUANTITATIVA (ROUGE + BIAS)

Esta célula preenche a lacuna de métricas formais exigidas pelo desafio. Ela avalia o modelo em três dimensões complementares: qualidade textual das respostas, especialização no domínio médico, e equidade entre grupos demográficos de pacientes.

10.1 Métricas ROUGE

ROUGE (Recall-Oriented Understudy for Gisting Evaluation) é um conjunto de métricas padrão para avaliar modelos de geração de texto. Ela compara a sobreposição de n-gramas entre as respostas geradas e as respostas de referência:

Métrica	O que mede e threshold esperado
ROUGE-1	Sobreposição de unigramas (palavras individuais) entre gerado e referência. ≥ 0.30 indica cobertura razoável.
ROUGE-2	Sobreposição de bigramas (pares de palavras consecutivas). ≥ 0.10 indica cobertura razoável de frases.
ROUGE-L	Longest Common Subsequence — mede preservação de sequências longas de palavras. ≥ 0.20 indica boa coerência.

10.2 Cobertura de Termos Médicos

Esta é uma métrica de domínio customizada para este trabalho — não existente em métricas padrão. Ela mede a proporção de termos clínicos especializados presentes nas respostas geradas, comparando com as respostas de referência. Termos avaliados incluem: ginecolog, obstetric, gestac, menstrua, anticoncepc, menopausa, papanicolau, mamografia, violencia, puerperio, entre outros em PT e EN.

10.3 Análise de Bias e Equidade Demográfica

O desafio exige explicitamente 'análise de bias e equidade entre grupos demográficos'. O código testa 4 dimensões críticas de potencial desigualdade nas respostas do modelo:

Dimensão de bias testada	Perfis avaliados e por que é importante
Faixa etária	Adolescente (16a) vs. Adulta (35a) vs. Idosa (62a) — ciclo irregular. Verifica se o modelo adapta adequadamente suas sugestões à faixa etária.
Contexto socioeconômico	Baixa renda (SUS) vs. Renda média vs. Alta renda (plano). Garante que todas as pacientes recebam orientações equânimes e que o SUS não seja tratado como inferior.

Dimensão de bias testada	Perfis avaliados e por que é importante
Contexto geográfico	Zona rural (sem acesso a especialistas) vs. Zona urbana. Verifica se o modelo considera limitações de acesso na orientação.
Origem étnica (percebida)	Indígena vs. Afrodescendente vs. Sem especificação — menopausa. Detecta se há diferenças sistemáticas no tratamento por etnia.

O sistema avalia variação de comprimento e cobertura médica entre os perfis. Variação acima de 40% sinaliza risco de bias sistêmico que exigiria revisão do dataset de treinamento.

11. CÉLULA 7 — BASE DE CONHECIMENTO VETORIAL COM FAISS (RAG)

Esta célula implementa o componente RAG (Retrieval-Augmented Generation). O RAG é uma técnica que permite ao modelo de linguagem 'consultar' uma base de conhecimento externa antes de responder, tornando as respostas mais precisas e fundamentadas em fontes verificáveis.

11.1 O que é RAG e por que é superior ao fine-tuning sozinho?

O fine-tuning incorpora conhecimento nos pesos do modelo — mas o modelo pode 'esquecer' detalhes específicos ou alucinar informações. O RAG resolve isso buscando os documentos mais relevantes no momento da pergunta e passando-os como contexto ao LLM. As vantagens são: (1) a base de conhecimento pode ser atualizada sem retreinar o modelo; (2) as respostas são fundamentadas em documentos específicos e citáveis; (3) reduz drasticamente as alucinações do modelo.

11.2 Documentos de Protocolo incluídos na base

Seis documentos sintéticos baseados em diretrizes brasileiras e internacionais foram adicionados manualmente pelo desenvolvedor:

Protocolo	Fonte e conteúdo principal
Triagem Ginecológica	FEBRASGO 2023 — classificação por cores (Verde/Amarela/Laranja/Vermelho), critérios diagnósticos para endometriose, SOP, DIP.
Violência Doméstica	Ministério da Saúde 2022 — notificação SINAN, medidas protetivas Lei Maria da Penha, profilaxia em violência sexual (<72h).
Pré-natal	FEBRASGO/OMS 2023 — mínimo 6 consultas, exames por trimestre, vacinação obrigatória (dTpa, influenza), TOTG 24-28 semanas.
Rastreamento Câncer de Mama	INCA 2023 — mamografia por faixa etária, critérios BI-RADS (0-6), indicação de biópsia para BI-RADS 4 e 5.
Saúde Mental Materna	Literatura Psiquiatria Perinatal / MS Brasil — Escala Edinburgh (EPDS >= 10), fatores de risco DPP, psicose puerperal como emergência.
Contracepção	FEBRASGO/ANVISA/Lei 9.263/1996 — métodos por eficácia, anticoncepção de emergência (levonorgestrel <72h, DIU cobre <120h).

11.3 Modelo de Embeddings: paraphrase-multilingual-MiniLM-L12-v2

O modelo sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2 foi escolhido por três razões complementares:

- Multilíngue — suporta português e inglês nativamente, essencial pois o dataset combina textos em ambos os idiomas (sintéticos PT + PubMedQA EN).
- Eficiente — modelo compacto (L12 = 12 camadas) que executa rapidamente mesmo em CPU, sem degradar significativamente a qualidade dos embeddings.
- Semântico — gera representações vetoriais que capturam significado (não apenas palavras), permitindo que uma busca por 'hematomas em paciente' recupere o documento de 'violência doméstica' mesmo que a palavra exata não esteja na query.

11.4 Como o FAISS funciona

O FAISS (Facebook AI Similarity Search) é uma biblioteca que cria um índice vetorial dos documentos. Quando o assistente recebe uma pergunta, o FAISS encontra os $k=3$ documentos com maior similaridade cossenoidal ao vetor da pergunta — em milissegundos, independentemente do tamanho da base. Esses 3 documentos são passados como contexto ao LLM, que os usa para formular uma resposta fundamentada.

12. CÉLULA 8 — ASSISTENTE MÉDICO COM LANGCHAIN

Esta célula integra todos os componentes anteriores em uma única classe: `AssistenteMedicoFeminino`. É aqui que o `LangChain` atua como 'cola' entre o modelo fine-tuned, a base vetorial e as regras de segurança.

12.1 Arquitetura do Assistente — fluxo de uma consulta

FLUXO COMPLETO DE UMA CONSULTA — <code>AssistenteMedicoFeminino</code>
1. Profissional faz uma pergunta ao assistente
2. Detecção de sensibilidade — verifica se a pergunta menciona violência doméstica ou emergência de saúde mental
3. Se emergência de saúde mental → logging CRITICAL. Se violência doméstica → logging WARNING
4. Retriever FAISS busca os 3 documentos mais relevantes na base vetorial
5. Prompt estruturado é montado: [regras de segurança] + [contexto dos 3 documentos] + [pergunta]
6. LLM fine-tuned gera a resposta baseada no prompt completo (<code>chain_type='stuff'</code>)
7. Validação de segurança — verifica termos proibidos na resposta gerada
8. Se termo proibido detectado → adiciona aviso automático à resposta
9. Interação registrada no log de auditoria com hash, timestamp e fontes
10. Retorno estruturado: resposta + fontes + validação + timestamp + aviso legal

12.2 Configuração do LLM Local

O modelo fine-tuned é carregado via `hf_pipeline` (Hugging Face Pipeline) e encapsulado pelo `HuggingFacePipeline` do `LangChain`. Os parâmetros de geração são:

Parâmetro de geração	Valor e justificativa
<code>max_new_tokens = 300</code>	Limita o tamanho da resposta. 300 tokens ~ 250 palavras, suficiente para orientações clínicas sem ser excessivo.
<code>temperature = 0.3</code>	Temperatura baixa = respostas mais determinísticas e precisas. Alta temperatura geraria variações criativas — indesejável em contexto médico.
<code>do_sample = True</code>	Habilita amostragem probabilística (necessário quando <code>temperature < 1.0</code>). Sem isso, o modelo usa busca gulosa pura.

Parâmetro de geração	Valor e justificativa
repetition_penalty = 1.2	Penaliza a repetição de tokens já gerados, melhorando a fluidez e evitando que o modelo repita a mesma frase em loop.
pad_token_id = 50256	Token de padding do GPT-2 (eos_token). Necessário para processar batches de tamanhos diferentes.

12.3 Template de Prompt Especializado

O prompt define o comportamento do assistente de forma explícita. As regras de segurança inseridas no prompt correspondem exatamente aos requisitos do desafio:

```
REGRAS OBRIGATÓRIAS DE SEGURANÇA:
- NUNCA prescreva medicamentos sem validação de especialista
- NUNCA emita diagnóstico definitivo
- SEMPRE recomende consulta presencial para sintomas alarmantes
- SEMPRE encaminhe casos de violência doméstica para equipe especializada
- MANTENHA confidencialidade absoluta em casos sensíveis
- Use linguagem inclusiva, empática e culturalmente respeitosa

CONTEXTO DOS PROTOCOLOS:
{context} ← 3 documentos do FAISS inseridos aqui

PERGUNTA DO PROFISSIONAL:
{question} ← pergunta do usuário
```

12.4 Detecção de Sensibilidade

O método `_detectar_sensibilidade` verifica se a pergunta contém palavras associadas a casos sensíveis. O dicionário `CATEGORIAS_SENSIVEIS` mapeia palavras-gatilho para categorias: 'violencia', 'abuso', 'agressao' → `violencia_domestica`; 'suicidio', 'automutilacao' → `emergencia_saude_mental`. Casos de emergência de saúde mental geram log `CRITICAL`; violência doméstica gera log `WARNING`.

12.5 Validação de Respostas

Antes de retornar ao usuário, cada resposta é verificada contra uma lista de termos proibidos: 'prescrevo', 'diagnostico definitivo', 'voce tem', 'certamente e', 'pode tomar sem consultar'. Se qualquer um for detectado, um aviso de revisão por protocolo de segurança é automaticamente adicionado à resposta. Isso implementa a validação do LLM antes do retorno exigida pelo desafio.

13. CÉLULA 9 — FLUXOS DE TRIAGEM COM LANGGRAPH

O LangGraph permite criar grafos de estados onde cada nodo é uma função Python e as arestas representam transições entre etapas. Os quatro fluxos implementados correspondem diretamente aos quatro fluxos exigidos pelo desafio.

13.1 Estado Compartilhado — EstadoPaciente

Todos os fluxos compartilham o mesmo TypedDict EstadoPaciente, que funciona como uma 'ficha de atendimento digital' preenchida progressivamente a cada nodo do grafo:

Campo do estado	Significado e como é preenchido
nome_anonimizado	Identificador da paciente sem dados pessoais (ex.: PAC_A3F9). Preenchido antes de invocar o fluxo.
idade	Idade da paciente em anos. Influencia sugestões de exames (Papanicolaou >=25a, Mamografia >=40a).
sintomas	Lista de sintomas relatados. O nodo de análise verifica quais sintomas críticos, altos ou moderados estão presentes.
historico	Histórico clínico relevante (ex.: 'SOP diagnosticada', 'hipertensão'). Influencia classificação de risco.
nivel_risco	Classificação: 'critico', 'alto', 'moderado' ou 'baixo'. Preenchido pelo primeiro nodo de cada fluxo.
classificacao_urgencia	Cor de urgência protocolo Manchester: VERMELHO/LARANJA/AMARELA/VERDE com tempo máximo de espera.
exames_sugeridos	Lista de exames recomendados com base no risco e idade da paciente.
encaminhamentos	Serviços ou especialistas para encaminhamento (DEAM, CREAS, ginecologista, psicologia etc.).
alertas	Avisos críticos gerados pelo sistema (ex.: 'URGENTE: Sangramento — encaminhar à maternidade').
orientacoes	Orientações ao profissional de saúde sobre como proceder.
proximos_passos	Ações imediatas: agendamentos, envio de SMS, atualização de prontuário.
log_fluxo	Lista acumulativa de entradas com horário (HH:MM:SS) de cada nodo. Usa operator.add para acumulação automática.

13.2 Fluxo 1 — Triagem Ginecológica

FLUXO 1 — TRIAGEM GINECOLÓGICA (5 nodos sequenciais)

1. **analisar_sintomas_ginecologicos** — classifica sintomas em crítico/alto/moderado/baixo (ex.: 'sangramento intenso' = crítico; 'ciclo irregular' = moderado)
▼
2. **classificar_urgencia** — converte nível de risco em classificação de cor: VERMELHO (0-10min) / LARANJA (2h) / AMARELA (24h) / VERDE (eletiva)
▼
3. **sugerir_exames_ginecologicos** — sugere exames por risco e idade: hemograma, USG, beta-hCG (alto/crítico); FSH/LH/TSH (ciclo irregular); Papanicolau >=25a; Mamografia >=40a
▼
4. **gerar_orientacoes_ginecologicas** — orientações ao profissional: crítico → acionar plantonista; alto → contato ginecologista no dia; baixo → agendamento eletivo
▼
5. **agendar_atendimento_ginecologico** — define prazo e próximos passos: imediato / 24h / 7 dias / 30 dias conforme risco

13.3 Fluxo 2 — Detecção de Violência Doméstica

FLUXO 2 — DETECÇÃO DE VIOLÊNCIA DOMÉSTICA (3 nodos + sigilo)

1. **avaliar_sinais_violencia** — calcula score de risco: sinais diretos pesam 2 (lesões inexplicadas, hematomas, medo do parceiro); indiretos pesam 1 (IST de repetição, depressão, isolamento). Score >=4 = crítico; >=2 = alto; >=1 = moderado
▼
2. **aplicar_protocolo_seguranca** — crítico/alto: aciona DEAM, CREAS, Casa da Mulher, Assistência Social, Psicologia e (se crítico) SAMU. Moderado/baixo: acolhimento e contatos de apoio
▼
3. **documentar_caso_violencia** — orienta: Ficha SINAN, prontuário restrito, fotografia com consentimento, armazenamento criptografado, sigilo absoluto, retorno seguro

13.4 Fluxo 3 — Avaliação Obstétrica

FLUXO 3 — AVALIAÇÃO OBSTÉTRICA (2 nodos sequenciais)

1. **avaliar_risco_gestacional** — classifica como alto risco se: diabetes gestacional, hipertensão, pré-eclâmpsia, gêmeos, placenta prévia, histórico de aborto, sangramento, febre, ausência de

movimentos fetais, idade <17 ou >35 anos. Alertas específicos para sangramento e ausência de MF (emergências)



2. gerar_plano_prenatal — exames de rotina 1º trimestre para todas; exames adicionais para alto risco (TOTG, proteinúria, cardiotocografia, Doppler). Próximos passos: pré-natal de alto risco, sulfato ferroso + ácido fólico, orientação sinais de alerta

13.5 Fluxo 4 — Prevenção e Acompanhamento (com aresta condicional)

FLUXO 4 — PREVENÇÃO E ACOMPANHAMENTO (aresta condicional)

1. identificar_exames_devidos — verifica por faixa etária: Papanicolau >=25a, Mamografia >=40a, Perfil lipídico >=45a, Densitometria >=50a, Glicemia >=60a, Vacina HPV <=45a (se não realizada). Identifica apenas exames NÃO registrados no histórico



2. ARESTA CONDICIONAL — se sem exames pendentes → 'sem_pendencias'; se há pendências → 'com_pendencias'. Ambos os caminhos passam por gerar_orientacoes_prev (garante que a paciente sempre receba orientação)



3. gerar_orientacoes_preventivas — sem pendências: mensagem de parabéns. Com pendências: solicitar exames, explicar importância, verificar acesso SUS; adiciona orientações de THM >=50a e cardiovascular >=60a



4. agendar_preventivo — sem pendências: consulta preventiva em 12 meses. Com pendências: solicitar exames hoje, retorno 30 dias, lembrete SMS/app, registrar no prontuário, verificar programa Viva Mulher SUS

Diferencial do Fluxo 4: Aresta Condicional

O Fluxo 4 é o único que utiliza `add_conditional_edges` do LangGraph — uma aresta que decide o próximo nó com base no estado atual. A função `decidir_continuidade_prevencao` verifica se há exames pendentes para direcionar o fluxo de forma inteligente. Isso demonstra o uso avançado do LangGraph além de grafos puramente sequenciais.

14. SEGURANÇA, VALIDAÇÃO E AUDITORIA

O desafio dedica uma seção inteira a segurança e validação. O trabalho implementa múltiplas camadas de proteção, correspondendo a cada requisito.

14.1 Limites de Atuação — Hard Rules

As seguintes regras são implementadas como verificações ativas no código, não apenas como instruções no prompt:

Regra do desafio	Implementação técnica no código
NUNCA prescrever medicações	Deteção de 'prescrevo' na resposta → aviso automático + log WARNING
NUNCA diagnosticar definitivamente	Deteção de 'diagnóstico definitivo', 'você tem', 'certamente é' → aviso + log
SEMPRE encaminhar violência doméstica	Deteção de palavras-gatilho → Fluxo 2 LangGraph com acionamento da rede de proteção
SEMPRE recomendar consulta presencial	Incluso em cada resposta do dataset sintético e no template do prompt
MANTER confidencialidade em violência	Logs de violência em nível WARNING separado; documentação em prontuário restrito orientada pelo Fluxo 2

14.2 Logging e Auditoria

O sistema de logging configurado na Célula 2 registra todos os eventos relevantes durante a execução:

- INFO — cada interação normal com o assistente (hash da pergunta + fontes utilizadas)
- WARNING — detecção de possível violência doméstica
- CRITICAL — detecção de emergência de saúde mental (suicídio, automutilação)
- ERROR — falhas na geração de resposta pelo LLM

O método `gerar_relatorio_auditoria()` da classe `AssistenteMedicoFeminino` permite gerar um `DataFrame` pandas com todas as interações registradas — atendendo ao requisito de 'relatórios de utilização por especialidade médica' do desafio.

14.3 Explainability

Cada resposta retornada pelo assistente inclui o campo 'fontes' — uma lista dos documentos recuperados pelo FAISS que embasaram a resposta, com o nome da fonte (ex.:

'FEBRASGO 2023'), a categoria e um preview do conteúdo. Isso atende ao critério de explainability do desafio: 'indicar fonte específica da informação' e 'mostrar nível de confiança nas sugestões'.

Aviso Legal em todas as respostas

Todas as respostas do assistente incluem o campo 'aviso_legal': 'Este assistente é ferramenta de apoio clínico. Não substitui avaliação médica presencial.' Este aviso é parte da resposta estruturada e não pode ser removido pelo usuário final.

15. INTEGRAÇÃO COMPLETA — COMO OS COMPONENTES SE CONECTAM

Este é o ponto mais importante para entender o trabalho como um todo: como os quatro componentes (fine-tuning, RAG, LangChain e LangGraph) se integram em uma solução coesa.

15.1 Dois modos de operação do sistema

O sistema pode ser usado de duas formas complementares:

Modo 1 — Consulta ao Assistente (LangChain + RAG)

Um profissional faz uma pergunta aberta ao assistente. O LangChain orchestra: retriever FAISS busca documentos relevantes, o LLM fine-tuned gera a resposta baseada no contexto recuperado. Ideal para dúvidas clínicas, consultas sobre protocolos, orientações gerais. Exemplo: 'Quais são os sinais de alerta na gravidez?'

Modo 2 — Triagem Estruturada (LangGraph)

O profissional entra com dados estruturados de uma paciente (idade, sintomas, histórico). O grafo LangGraph percorre cada nodo do fluxo correspondente, preenchendo progressivamente o estado da paciente até gerar: nível de risco, classificação de urgência, exames sugeridos, encaminhamentos e próximos passos. Ideal para triagem padronizada e rastreável. Exemplo: Fluxo Ginecológico com paciente de 35 anos com dor pélvica crônica.

15.2 Fluxo de dados ponta a ponta

Dado de entrada	Percurso no sistema e saída
Arquivo JSON PubMedQA (1.000 registros)	Célula 3: filtro → ~270 registros relevantes → Célula 4: combinação com sintéticos → df_treino (~280 registros)
df_treino (~280 registros)	Célula 5: anonimização + normalização + template Alpaca → df_processado com coluna texto_fine_tuning
df_processado (coluna texto_fine_tuning)	Célula 6: tokenização → fine-tuning LoRA → modelo salvo em ./modelo_saude_mulher_final
6 documentos de protocolo + registros PubMedQA	Célula 7: embeddings MiniLM → índice FAISS → salvo em ./base_vetorial_saude_mulher
modelo fine-tuned + índice FAISS	Célula 8: HuggingFacePipeline + FAISS retriever → classe AssistenteMedicoFeminino

Dado de entrada	Percurso no sistema e saída
Pergunta do profissional (string)	Assistente: detecção sensibilidade → recuperação FAISS → prompt montado → LLM gera → validação → log → dict retornado
Dados da paciente (dict com idade/sintomas/histórico)	LangGraph: fluxo adequado → nodos preenchem estado → dict final com risco/exames/orientações/log

16. CONSIDERAÇÕES ÉTICAS E REGULATÓRIAS

16.1 LGPD — Lei Geral de Proteção de Dados

O trabalho implementa instrumentos de aderência à LGPD em múltiplas camadas: anonimização de dados pessoais no pré-processamento (Célula 5), hash SHA-256 para rastreabilidade sem expor conteúdo, logs sem dados pessoais identificáveis (apenas hashes), e orientação no Fluxo 2 para armazenamento criptografado de dados de violência doméstica.

16.2 Assistente como Ferramenta de Apoio, não Substituto

Este é o princípio mais importante do trabalho: o assistente é explicitamente posicionado como ferramenta de apoio à decisão clínica, nunca como substituto do profissional de saúde. Isso se manifesta tecnicamente em: aviso legal em todas as respostas, regras proibindo diagnósticos definitivos e prescrições, sempre recomendando consulta presencial em sintomas alarmantes, e o disclaimer no início do notebook.

16.3 Sensibilidade Cultural e Equidade

A análise de bias (Célula 6b) verifica se o modelo trata pacientes de diferentes origens étnicas, faixas de renda e contextos geográficos de forma equânime. O template de prompt instrui explicitamente o modelo a usar 'linguagem inclusiva, empática e culturalmente respeitosa'. Os dados sintéticos incluem casos de pacientes indígenas, afrodescendentes, de zona rural e de baixa renda.

16.4 Protocolo específico para violência doméstica

O Fluxo 2 implementa o protocolo do Ministério da Saúde para violência contra a mulher: notificação compulsória via Ficha SINAN, acionamento da rede de proteção (DEAM, CREAS, Casa da Mulher Brasileira), documentação segura com sigilo absoluto, e profilaxia de IST/anticoncepção de emergência nas primeiras 72 horas. Esses elementos são baseados na Lei 11.340/2006 (Lei Maria da Penha) e nas normativas do Ministério da Saúde.

Declaração de Escopo Acadêmico

Este sistema é um protótipo acadêmico desenvolvido para a disciplina de pós-graduação POSTECH — IA para DEVs, Fase 3. Não deve ser utilizado em ambiente clínico real sem validação por especialistas em ginecologia e obstetrícia, adequação às normas do CFM, auditoria de segurança, e homologação pelo sistema hospitalar. Todas as orientações geradas são de apoio à decisão e não substituem a avaliação presencial por profissional habilitado.

— *Fim da Documentação Técnica* —

The image features the FIAP logo in a white, minimalist, sans-serif font, centered on a dark blue background. The logo consists of the letters 'FIAP', where the 'I' and 'A' are connected. A thin, light blue diagonal line runs from the top left towards the center. A larger, faint, light blue curved line arcs across the middle of the image, passing behind the logo. In the bottom right corner, there is a dark blue semi-circular shape. Along the bottom edge, there are several small, light blue dots and a small white triangle pointing upwards in the bottom right corner.

FIAP