



# FIAP

# RELATÓRIO TÉCNICO



Alexandre Natã Vicente  
Antônio Cláudio Almeida  
Cyd Ferreira Rodrigues  
David Catherink  
Marcelo Macedo Klotz

POSTECH — INTELIGÊNCIA ARTIFICIAL PARA DEVS

## FASE 3 — TECH CHALLENGE

**Assistente Virtual Especializado em Saúde da Mulher**

*com Fine-tuning LoRA · RAG/FAISS · LangChain · LangGraph*

# SUMÁRIO

---

|                                                                                    |    |
|------------------------------------------------------------------------------------|----|
| 1. Contexto e Objetivos do Trabalho .....                                          | 5  |
| 1.1 Grupo de trabalho.....                                                         | 5  |
| 1.2 Links relacionados.....                                                        | 5  |
| 1.3 Componentes utilizados .....                                                   | 6  |
| 2. Visão Geral da Arquitetura .....                                                | 7  |
| 3. Dataset — PubMedQA e Dados Sintéticos .....                                     | 8  |
| 3.1 O que é o PubMedQA (ori_pqal.json).....                                        | 8  |
| 3.2 Filtro de Relevância — Como o Código Seleciona Registros.....                  | 8  |
| 3.3 Mapeamento de Categorias .....                                                 | 9  |
| 3.4 Dataset Sintético (10 registros manuais) .....                                 | 10 |
| 4. Célula 1 — Instalação de Dependências.....                                      | 11 |
| 4.1 Por que a ordem de instalação importa? .....                                   | 11 |
| 4.2 Tabela de Dependências — O que é cada biblioteca e por que foi escolhida ..... | 11 |
| 5. Célula 2 — Imports e Configuração Geral.....                                    | 13 |
| 5.1 Sistema de Logging para Auditoria .....                                        | 13 |
| 5.2 Semente Aleatória (SEED = 42) .....                                            | 13 |
| 5.3 TypedDict para Tipagem dos Estados .....                                       | 13 |
| 6. Célula 3 — Carregamento e Filtro do PubMedQA.....                               | 14 |
| 6.1 Download Direto do GitHub .....                                                | 14 |
| 6.2 Pipeline de Transformação dos Registros .....                                  | 14 |
| 6.3 Mecanismo de Fallback.....                                                     | 14 |
| 7. Célula 4 — Dataset Sintético de Saúde da Mulher.....                            | 15 |
| 7.1 Por que dados sintéticos em saúde? .....                                       | 15 |
| 7.2 Estrutura de cada registro sintético.....                                      | 15 |
| 8. Célula 5 — Pré-processamento e Anonimização .....                               | 16 |
| 8.1 Anonimização com Expressões Regulares.....                                     | 16 |
| 8.2 Normalização Terminológica .....                                               | 16 |
| 8.3 Template Alpaca para Fine-tuning.....                                          | 17 |
| 8.4 Hash de Anonimização e Timestamp .....                                         | 17 |
| 9. Célula 6 — Fine-tuning com PEFT/LoRA.....                                       | 18 |
| 9.1 O que é Fine-tuning e por que é necessário? .....                              | 18 |
| 9.2 Por que LoRA (Low-Rank Adaptation)? .....                                      | 18 |
| 9.3 Parâmetros LoRA utilizados e suas justificativas .....                         | 18 |
| 9.4 Otimizações implementadas (e por que foram necessárias).....                   | 19 |

|                                                                    |    |
|--------------------------------------------------------------------|----|
| 9.5 Modelo Base: por que GPT-2?                                    | 19 |
| 10. Célula 6b — Avaliação Quantitativa (ROUGE + Bias)              | 20 |
| 10.1 Métricas ROUGE                                                | 20 |
| 10.2 Cobertura de Termos Médicos                                   | 20 |
| 10.3 Análise de Bias e Equidade Demográfica                        | 20 |
| 11. Célula 7 — Base de Conhecimento Vetorial com FAISS (RAG)       | 22 |
| 11.1 O que é RAG e por que é superior ao fine-tuning sozinho?      | 22 |
| 11.2 Documentos de Protocolo incluídos na base                     | 22 |
| 11.3 Modelo de Embeddings: paraphrase-multilingual-MiniLM-L12-v2   | 22 |
| 11.4 Como o FAISS funciona                                         | 23 |
| 12. Célula 8 — Assistente Médico com LangChain                     | 24 |
| 12.1 Arquitetura do Assistente — fluxo de uma consulta             | 24 |
| 12.2 Configuração do LLM Local                                     | 24 |
| 12.3 Template de Prompt Especializado                              | 25 |
| 12.4 Detecção de Sensibilidade                                     | 25 |
| 12.5 Validação de Respostas                                        | 25 |
| 13. Célula 9 — Fluxos de Triagem com LangGraph                     | 26 |
| 13.1 Estado Compartilhado — EstadoPaciente                         | 26 |
| 13.2 Fluxo 1 — Triagem Ginecológica                                | 27 |
| 13.3 Fluxo 2 — Detecção de Violência Doméstica                     | 27 |
| 13.4 Fluxo 3 — Avaliação Obstétrica                                | 27 |
| 13.5 Fluxo 4 — Prevenção e Acompanhamento (com aresta condicional) | 28 |
| 14. Segurança, Validação e Auditoria                               | 29 |
| 14.1 Limites de Atuação — Hard Rules                               | 29 |
| 14.2 Logging e Auditoria                                           | 29 |
| 14.3 Explainability                                                | 29 |
| 15. Integração Completa — Como os Componentes se Conectam          | 31 |
| 15.1 Dois modos de operação do sistema                             | 31 |
| 15.2 Fluxo de dados ponta a ponta                                  | 31 |
| 16. Considerações Éticas e Regulatórias                            | 33 |
| 16.1 LGPD — Lei Geral de Proteção de Dados                         | 33 |
| 16.2 Assistente como Ferramenta de Apoio, não Substituto           | 33 |
| 16.3 Sensibilidade Cultural e Equidade                             | 33 |
| 16.4 Protocolo específico para violência doméstica                 | 33 |

# 1. CONTEXTO E OBJETIVOS DO TRABALHO

---

Este documento explica de forma completa e acessível o trabalho de conclusão da Fase 3 da pós-graduação em Inteligência Artificial para DEVs da POSTECH. O trabalho consiste na construção de um protótipo de assistente virtual médico especializado em saúde da mulher, utilizando quatro tecnologias centrais de Inteligência Artificial moderna, a partir do desafio, disponibilizado no repositório do Github para referência ([PDF](#)).

## Sobre o desafio proposto

Redes hospitalares especializadas em saúde feminina necessitam de apoio computacional para triagem clínica, identificação de situações de risco (como violência doméstica), acompanhamento obstétrico e ações de prevenção. O assistente criado neste trabalho automatiza esses fluxos, sempre com validação humana obrigatória.

## 1.1 Grupo de trabalho

O grupo responsável por este desafio foi composto pelos seguintes integrantes da Secretaria de Segurança Pública do Distrito Federal (SSP/DF):

- **Alexandre Natã Vicente** (rm370024) ([ale.n.vicente@gmail.com](mailto:ale.n.vicente@gmail.com))
- **Antônio Cláudio Almeida** (rm370052) ([antonioalmeida@gmail.com](mailto:antonioalmeida@gmail.com))
- **Cyd Ferreira Rodrigues** (rm370004) ([cydnelson@gmail.com](mailto:cydnelson@gmail.com))
- **David Catherinck** (rm369997) ([d.catherinck@gmail.com](mailto:d.catherinck@gmail.com))
- **Marcelo Macedo Klotz** (rm370010) ([marceloklotz@gmail.com](mailto:marceloklotz@gmail.com))

## 1.2 Links relacionados

Os arquivos relacionados a este desafio podem ser acessados por meio dos seguintes endereços eletrônicos:

- **Repositório do Github da Terceira Fase:**  
<https://github.com/marceloklotz/fiap-terceira-fase-ssp-df/>
- **Notebook:**  
[https://github.com/marceloklotz/fiap-terceira-fase-ssp-df/blob/main/FIAP\\_Fase\\_3.ipynb](https://github.com/marceloklotz/fiap-terceira-fase-ssp-df/blob/main/FIAP_Fase_3.ipynb)
- **Vídeo explicativo disponível a partir do README do repositório no Github:**  
<https://github.com/marceloklotz/fiap-terceira-fase-ssp-df/blob/main/README.md>
- **Base de dados (link da fonte original):**  
[https://raw.githubusercontent.com/pubmedqa/pubmedqa/refs/heads/master/data/ori\\_pqal.json](https://raw.githubusercontent.com/pubmedqa/pubmedqa/refs/heads/master/data/ori_pqal.json)

### 1.3 Componentes utilizados

O trabalho entrega quatro componentes integrados, conforme requisitos do desafio proposto:

| Componente              | Descrição e Tecnologia                                                                                                                                               |
|-------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Fine-tuning LoRA</b> | Ajuste fino do modelo GPT-2 com a técnica LoRA, usando dados biomédicos reais (PubMedQA) e sintéticos baseados em diretrizes brasileiras (FEBRASGO, INCA, OMS).      |
| <b>RAG + FAISS</b>      | Base de conhecimento vetorial com 6 protocolos clínicos e registros do PubMedQA. Busca semântica em milissegundos via FAISS, integrada ao LangChain.                 |
| <b>LangChain</b>        | Pipeline de integração entre o modelo fine-tuned, a base vetorial e as regras de segurança. Classe AssistenteMedicoFeminino com validação, logging e explainability. |
| <b>LangGraph</b>        | Quatro grafos de estado orquestrando fluxos clínicos: Triagem Ginecológica, Detecção de Violência Doméstica, Avaliação Obstétrica e Prevenção.                       |

## 2. VISÃO GERAL DA ARQUITETURA

---

A arquitetura do trabalho é modular e em camadas. Cada camada tem uma responsabilidade específica e se comunica com as demais por interfaces bem definidas. O diagrama abaixo representa o fluxo completo de dados e decisões:

|                                                                                                                                            |
|--------------------------------------------------------------------------------------------------------------------------------------------|
| <b>ENTRADA DE DADOS</b><br>PubMedQA (1.000 artigos biomédicos) + 10 registros sintéticos FEBRASGO/INCA/OMS                                 |
| <b>ETAPA 1 — PRÉ-PROCESSAMENTO</b><br>Anonimização (LGPD) → Normalização terminológica → Formatação template Alpaca                        |
| <b>ETAPA 2 — FINE-TUNING LoRA</b><br>GPT-2 + adaptadores LoRA (r=8, alpha=32) → modelo especializado em saúde feminina → salvo em disco    |
| <b>ETAPA 3 — BASE VETORIAL RAG</b><br>Embeddings multilíngues (MiniLM) → índice FAISS → busca semântica k=3                                |
| <b>ETAPA 4 — ASSISTENTE LANGCHAIN</b><br>LLM fine-tuned + Retriever FAISS + Prompt especializado + Validação segurança + Logging auditoria |
| <b>ETAPA 5 — FLUXOS LANGGRAPH</b><br>4 grafos de estado: Triagem Ginecológica / Violência Doméstica / Obstétrico / Prevenção               |
| <b>SAÍDA ESTRUTURADA</b><br>Resposta + Fontes citáveis + Nível de confiança + Validação segurança + Log auditoria                          |

## 3. DATASET — PUBMEDQA E DADOS SINTÉTICOS

### 3.1 O que é o PubMedQA (ori\_pqal.json)

O PubMedQA é um benchmark biomédico amplamente reconhecido na comunidade científica. Ele contém **1.000 perguntas clínicas extraídas de artigos publicados no PubMed** (base de dados de literatura médica da Biblioteca Nacional de Medicina dos EUA). Cada registro no arquivo JSON possui:

| Campo no JSON  | Significado e Uso no Trabalho                                                                                                     |
|----------------|-----------------------------------------------------------------------------------------------------------------------------------|
| QUESTION       | A pergunta clínica original do artigo. Usada como 'instrucao' no template de fine-tuning.                                         |
| CONTEXTS       | Lista de parágrafos dos abstracts dos artigos que embasam a resposta. Usado como contexto bruto na base vetorial RAG.             |
| LONG_ANSWER    | Resposta longa derivada do artigo. Usada como 'resposta' no par instrução-resposta para fine-tuning.                              |
| MESHES         | Termos MeSH (Medical Subject Headings) — vocabulário controlado da medicina. Usado para inferir a categoria temática do registro. |
| final_decision | Decisão do artigo: 'yes', 'maybe' ou 'no'. Convertida em nível de confiança numérico: yes=0.90, maybe=0.72, no=0.55.              |
| YEAR           | Ano de publicação do artigo. Relevante para rastreabilidade e atualidade das informações.                                         |

#### Por que o PubMedQA foi escolhido?

O desafio exige que o fine-tuning seja realizado com 'dados específicos da área'. O PubMedQA fornece literatura biomédica revisada por pares, com fonte citável (PMID) — atendendo ao critério de “*explainability*”. Aproximadamente 27% dos registros cobrem temas de saúde feminina diretamente relevantes (ginecologia, obstetrícia, contracepção, câncer de mama, violência, saúde mental materna). O *download* é feito diretamente do GitHub oficial do projeto, sem necessidade de Google Drive.

### 3.2 Filtro de Relevância — Como o Código Seleciona Registros

Nem todos os 1.000 registros do PubMedQA são relevantes para saúde da mulher. O código implementa um filtro por palavras-chave que verifica se o campo QUESTION, LONG\_ANSWER ou MESHES contém termos como: *gynecol, obstetric, pregnan, menstrual, breast cancer, domestic violence, contraceptiv, menopause, prenatal, postpartum, reproduct, cervical, uterine, ovarian, maternal, endometri, mammograph, female, woman, women, gender, fertility, eclampsia, placenta, lactation, breastfeed*



O resultado é um subconjunto de registros biomédicos com alta relevância para o domínio do trabalho, que foram então convertidos para o formato interno do projeto (campos: instrucao, resposta, categoria, fonte, nivel\_confianca).

### 3.3 Mapeamento de Categorias

Cada registro filtrado recebe uma categoria temática inferida automaticamente a partir dos campos QUESTION e MESHES. O mapeamento é:

| Palavra-chave no texto                        | Categoria inferida   |
|-----------------------------------------------|----------------------|
| <b>breast, mammograph</b>                     | rastreamento_mama    |
| <b>cervical</b>                               | prevencao            |
| <b>uterine, ovarian, endometri, menstrual</b> | ginecologia          |
| <b>pregnan, obstetric, prenatal, maternal</b> | obstetricia          |
| <b>postpartum</b>                             | saude_mental_materna |
| <b>contraceptiv</b>                           | contracepcao         |
| <b>menopause</b>                              | climaterio           |
| <b>reproduct, lactation, breastfeed</b>       | saude_reprodutiva    |
| <b>violence</b>                               | violencia_domestica  |
| <b>(nenhuma correspondência)</b>              | medicina_geral       |

### 3.4 Dataset Sintético (10 registros manuais)

Além do PubMedQA, o trabalho inclui 10 registros criados manualmente em português, baseados em diretrizes brasileiras e internacionais. Esses registros cobrem os temas mais sensíveis e relevantes do atendimento à saúde feminina no Brasil:

| Tema                                           | Fonte de Referência                            |
|------------------------------------------------|------------------------------------------------|
| Irregularidade menstrual e SOP                 | FEBRASGO — Distúrbios Menstruais 2023          |
| Sintomas e diagnóstico de endometriose         | FEBRASGO — Endometriose 2022                   |
| Efeitos colaterais dos anticoncepcionais orais | ANVISA + FEBRASGO 2023                         |
| Sinais de alerta na gestação (pré-eclâmpsia)   | OMS / FEBRASGO Emergências Obstétricas 2023    |
| Identificação de depressão pós-parto           | DSM-5 / Escala Edinburgh / Protocolo MS Brasil |
| Protocolo de violência doméstica (SINAN)       | Ministério da Saúde / Lei Maria da Penha       |
| Periodicidade do Papanicolau                   | INCA — Diretrizes Rastreamento 2023            |
| Rastreamento de câncer de mama                 | INCA + American Cancer Society                 |
| Manejo do climatério e menopausa               | FEBRASGO — Consenso Climatério 2023            |
| Ansiedade severa em mulheres                   | Protocolo MS — Saúde Mental na APS / DSM-5     |

#### Nota importante sobre os dados sintéticos

Os registros sintéticos são inspirados em diretrizes nacionais e internacionais, **mas não reproduzem integralmente nenhum protocolo oficial**. Em um sistema real, a base de dados deve ser construída diretamente a partir de protocolos institucionais validados, devidamente versionados e com revisão especializada.

## 4. CÉLULA 1 — INSTALAÇÃO DE DEPENDÊNCIAS

A primeira célula do notebook instala e verifica todas as bibliotecas necessárias. A ordem de instalação é deliberada e tecnicamente importante — não é aleatória.

### 4.1 Por que a ordem de instalação importa?

O ecossistema LangChain/LangGraph possui dependências interdependentes. **Instalar fora de ordem ou com versões conflitantes gera erros difíceis de diagnosticar.** Por isso o código:

- Passo 1 — Desinstala instalações anteriores conflitantes (langchain, langgraph etc.)
- Passo 2 — Instala numpy com versão controlada (2.0–2.5), necessário para compatibilidade com FAISS e PyTorch
- Passo 3 — Instala o ecossistema LangChain completo com versões mínimas definidas
- Passo 4 — Instala langgraph separadamente (orquestrador de fluxos)
- Passo 5 — Instala bibliotecas de ML: transformers, datasets, peft, trl, accelerate, bitsandbytes
- Passo 6 — Instala ferramentas vetoriais: sentence-transformers e faiss-cpu
- Passo 7 — Instala utilitários: ijson, cryptography, rouge\_score, evaluate

### 4.2 Tabela de Dependências — O que é cada biblioteca e por que foi escolhida

| Biblioteca / Versão mínima               | Função no projeto e justificativa da escolha                                                                     |
|------------------------------------------|------------------------------------------------------------------------------------------------------------------|
| <b>langchain &gt;= 1.0.0</b>             | Framework de orquestração de LLMs. Permite encadear LLM + retriever + prompt em um único pipeline (RetrievalQA). |
| <b>langchain-core &gt;= 1.3.3</b>        | Núcleo do LangChain: define interfaces, PromptTemplate, Document e componentes base usados em todo o projeto.    |
| <b>langchain-community &gt;= 0.4.1</b>   | Integrações com ferramentas externas. Contém o FAISS como VectorStore.                                           |
| <b>langchain-huggingface &gt;= 1.2.2</b> | Integração do LangChain com modelos Hugging Face (HuggingFacePipeline, HuggingFaceEmbeddings).                   |
| <b>langchain-classic</b>                 | Versão estável de chains clássicas como RetrievalQA, necessária para a classe do assistente.                     |
| <b>langgraph &gt;= 1.1.9</b>             | Orquestrador de grafos de estado. Permite criar os 4 fluxos clínicos com nodos, arestas e estado compartilhado.  |
| <b>transformers &gt;= 4.40.0</b>         | Biblioteca Hugging Face para carregar, tokenizar e gerar texto com modelos de linguagem (GPT-2, LLaMA, Falcon).  |
| <b>peft &gt;= 0.10.0</b>                 | Parameter-Efficient Fine-Tuning — implementa LoRA, QLoRA e outros métodos de ajuste fino eficiente de LLMs.      |

| Biblioteca / Versão mínima               | Função no projeto e justificativa da escolha                                                                                  |
|------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------|
| <b>trl &gt;= 0.8.0</b>                   | Transformer Reinforcement Learning — facilita fine-tuning supervisionado com SFTTrainer e outros treinadores.                 |
| <b>datasets &gt;= 2.18.0</b>             | Manipulação eficiente de datasets no formato Hugging Face, com suporte a tokenização em lote e splits automáticos.            |
| <b>accelerate &gt;= 0.27.0</b>           | Abstração de hardware para treinamento em CPU, GPU única ou múltiplas GPUs sem alterações no código.                          |
| <b>bitsandbytes &gt;= 0.43.0</b>         | Quantização de modelos em 4-bit/8-bit. Reduz uso de VRAM para fine-tuning de modelos grandes em GPUs menores.                 |
| <b>sentence-transformers &gt;= 2.7.0</b> | Gera embeddings semânticos de frases para alimentar o índice FAISS. Modelo multilíngue MiniLM usado no projeto.               |
| <b>faiss-cpu &gt;= 1.8.0</b>             | Facebook AI Similarity Search — busca vetorial por similaridade semântica em milissegundos, mesmo com milhares de documentos. |
| <b>rouge_score + evaluate</b>            | Métricas ROUGE-1/2/L para avaliação quantitativa da qualidade das respostas geradas pelo modelo.                              |
| <b>ijson</b>                             | Parser JSON incremental — lê o arquivo JSON de 1.000 registros do PubMedQA sem carregar tudo na memória de uma vez.           |
| <b>torchao &gt;= 0.16.0</b>              | Otimizações de memória e velocidade para PyTorch, especialmente útil no Colab com GPU T4.                                     |

## 5. CÉLULA 2 — IMPORTS E CONFIGURAÇÃO GERAL

---

Esta célula realiza a configuração fundamental do ambiente de execução. Três aspectos merecem atenção especial:

### 5.1 Sistema de Logging para Auditoria

Trata-se de requisito contido na seção 'Logging e auditoria especializados' do desafio, que foi configurado no código, conforme abaixo:

- Nível INFO como padrão — registra todas as interações normais
- Formato estruturado: data/hora | nível | mensagem — permite filtrar logs por período ou severidade
- Dois handlers simultâneos: StreamHandler (terminal) e FileHandler (arquivo auditoria\_assistente.log)
- Nome específico 'AssistenteMedicoFeminino' — identifica o logger nas aplicações com múltiplos módulos

#### Por que registrar em arquivo E no terminal?

O StreamHandler permite monitorar a execução em tempo real durante o desenvolvimento e demonstrações. O FileHandler persiste os logs em disco, permitindo auditoria posterior de todas as interações — fundamental em aplicações de saúde onde a rastreabilidade é exigência regulatória (LGPD, normas do CFM).

### 5.2 Semente Aleatória (SEED = 42)

A linha `random.seed(42)` e `np.random.seed(42)` garante reprodutibilidade dos experimentos. Isso significa que se o notebook for executado duas vezes com os mesmos dados, os resultados serão idênticos — essencial para comparar versões do modelo e para validação científica dos resultados.

### 5.3 TypedDict para Tipagem dos Estados

A importação de TypedDict do módulo typing é usada nas células do LangGraph para definir a estrutura do EstadoPaciente — o dicionário tipado que representa a 'ficha de atendimento' que percorre cada nodo dos grafos de triagem.

## 6. CÉLULA 3 — CARREGAMENTO E FILTRO DO PUBMEDQA

Esta célula realiza o download automático do dataset PubMedQA do GitHub oficial, filtra os registros relevantes para saúde feminina e os transforma no formato interno do projeto.

### 6.1 Download Direto do GitHub

O código usa `urllib.request.urlopen` para baixar o arquivo JSON diretamente da URL pública do repositório oficial do PubMedQA no GitHub. Isso elimina a dependência do Google Drive, tornando o notebook mais portátil e reproduzível em qualquer ambiente.

### 6.2 Pipeline de Transformação dos Registros

A função `converter_registro` transforma cada registro do formato original do PubMedQA para o formato interno do projeto. O mapeamento é:

| Campo PubMedQA original        | Campo interno gerado                                        |
|--------------------------------|-------------------------------------------------------------|
| PMID (chave do dict)           | fonte = 'PubMed PMID:XXXXX   MeSH1, MeSH2, MeSH3'           |
| QUESTION                       | instrucao (a pergunta a ser respondida pelo modelo)         |
| LONG_ANSWER                    | resposta (resposta baseada em evidências)                   |
| CONTEXTS (lista de parágrafos) | contextos_raw (texto bruto para enriquecer a base vetorial) |
| final_decision (yes/maybe/no)  | nivel_confianca (0.90 / 0.72 / 0.55)                        |
| MESHES + QUESTION (combinados) | categoria (inferida por palavras-chave)                     |

### 6.3 Mecanismo de Fallback

O bloco `try/except` garante que, se o download do PubMedQA falhar (por problemas de rede, timeout ou outros), o notebook continua sua execução usando apenas o dataset sintético da Célula 4. Isso torna o trabalho robusto mesmo em ambientes com conectividade limitada.

## 7. CÉLULA 4 — DATASET SINTÉTICO DE SAÚDE DA MULHER

O dataset sintético serve a dois propósitos complementares: (1) garantir cobertura de temas clinicamente críticos em português (o PubMedQA é majoritariamente em inglês); e (2) fornecer dados de treinamento baseados nas diretrizes brasileiras (FEBRASGO, INCA, Ministério da Saúde) que são as referências aplicáveis no contexto hospitalar nacional.

### 7.1 Por que dados sintéticos em saúde?

Dados reais de pacientes são protegidos pela LGPD (Lei Geral de Proteção de Dados) e por normas do CFM (Conselho Federal de Medicina). Em um protótipo acadêmico é inviável usar prontuários reais. Dados sintéticos — gerados manualmente por especialistas ou com auxílio de IA, mas revisados — permitem desenvolver e testar pipelines sem expor informações sensíveis. Esta é prática padrão em pesquisa de IA em saúde.

### 7.2 Estrutura de cada registro sintético

| Campo                  | Conteúdo e propósito                                                                                                                                 |
|------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>instrucao</b>       | A pergunta clínica ou situação apresentada ao assistente. Ex.: 'Quais são os sinais de alerta na gravidez?'                                          |
| <b>resposta</b>        | Orientação especializada detalhada, sempre com aviso de que não substitui consulta médica.                                                           |
| <b>categoria</b>       | Tag temática: ginecologia, contracepcao, obstetricia, saude_mental_materna, violencia_domestica, prevencao, climaterio, saude_mental.                |
| <b>fonte</b>           | Referência à diretriz que embasou a resposta. Ex.: 'FEBRASGO 2023', 'INCA 2023', 'Lei Maria da Penha'.                                               |
| <b>nivel_confianca</b> | Score de 0 a 1 indicando confiança estimada. Registros sintéticos têm scores entre 0.90 e 0.98, refletindo sua ancoragem em diretrizes consolidadas. |

#### Combinação dos dois datasets

Ao final da Célula 4, o código combina os 10 registros sintéticos com todos os registros filtrados do PubMedQA em um único DataFrame `df_treino`. Este DataFrame combinado é o que alimenta todo o pipeline subsequente de pré-processamento e fine-tuning. A combinação garante cobertura bilíngue (PT/EN) e diversidade de fontes (diretrizes brasileiras + literatura biomédica internacional).

## 8. CÉLULA 5 — PRÉ-PROCESSAMENTO E ANONIMIZAÇÃO

A classe `PreProcessadorMedicoFeminino` implementa o pipeline de preparação dos dados para o fine-tuning. Esta etapa é fundamental por dois motivos: segurança (remoção de dados pessoais, LGPD) e qualidade do modelo (normalização terminológica e formatação adequada para fine-tuning).

### 8.1 Anonimização com Expressões Regulares

A anonimização detecta e substitui padrões de dados pessoais identificáveis no texto, usando expressões regulares (regex). Os padrões implementados são:

| Padrão detectado                                  | Substituição aplicada    |
|---------------------------------------------------|--------------------------|
| CPF (000.000.000-00)                              | [CPF_ANONIMIZADO]        |
| Data de nascimento (dd/mm/yyyy)                   | [DATA_NASCIMENTO]        |
| CEP (00000-000)                                   | [CEP]                    |
| Telefone (com ou sem DDD)                         | [TELEFONE]               |
| Endereço de e-mail                                | [EMAIL]                  |
| Número de prontuário (ex.: 'Prontuário nº 12345') | [PRONTUARIO_ANONIMIZADO] |
| Sequência de 7 dígitos isolados                   | [ID_PACIENTE]            |

Esta etapa simula a conformidade com a LGPD para sistemas de saúde, onde dados de pacientes devem ser anonimizados antes de qualquer processamento por sistemas de IA.

### 8.2 Normalização Terminológica

A normalização converte termos leigos para terminologia médica padronizada. Isso melhora a coerência do vocabulário do dataset e aproxima os textos ao linguajar de protocolos clínicos. Exemplos:

| Termo leigo (entrada) | Termo médico (saída)       |
|-----------------------|----------------------------|
| remédios / remédio    | medicamentos / medicamento |
| dor de barriga        | dor abdominal              |
| dor nas costas        | lombalgia                  |
| enjoo na gravidez     | emese gravídica            |



| Termo leigo (entrada) | Termo médico (saída) |
|-----------------------|----------------------|
| menstruação atrasada  | atraso menstrual     |
| grávida               | gestante             |

### 8.3 Template Alpaca para Fine-tuning

O formato Alpaca é um padrão amplamente adotado para fine-tuning de LLMs orientados a instruções (como LLaMA, Falcon e GPT-2). Ele estrutura cada exemplo de treinamento em três seções:

```
### Instrucao:
Voce e um assistente medico especializado em saude da mulher.
Responda de forma precisa, empatica e sempre recomende avaliacao
presencial quando necessario.

{instrucao - a pergunta clinica}

### Resposta:
{resposta - a orientacao especializada}
```

Este formato ensina ao modelo o padrão input→output desejado, além de estabelecer a persona do assistente logo no início. A instrução de sistema (papel do assistente) é repetida em cada exemplo para que o modelo internalize esse comportamento.

### 8.4 Hash de Anonimização e Timestamp

O pipeline adiciona dois campos de rastreabilidade a cada registro processado: (1) hash\_anonizacao — hash SHA-256 dos 12 primeiros caracteres da instrução processada, que permite verificar se um registro foi alterado sem expor seu conteúdo; e (2) timestamp\_processamento — data/hora do processamento, essencial para auditorias de quando os dados foram preparados.

## 9. CÉLULA 6 — FINE-TUNING COM PEFT/LORA

Esta é a etapa central do trabalho do ponto de vista de aprendizado de máquina. O fine-tuning adapta um modelo de linguagem pré-treinado (GPT-2) para o domínio específico de saúde da mulher, sem precisar retreinar o modelo do zero.

### 9.1 O que é Fine-tuning e por que é necessário?

Modelos de linguagem como GPT-2, LLaMA e Falcon são pré-treinados em grandes corpora textuais genéricos (livros, artigos, internet). Eles compreendem linguagem, mas não possuem conhecimento especializado de saúde feminina nem seguem protocolos médicos específicos. O fine-tuning 'recalibra' os pesos do modelo para que ele responda de forma especializada, usando a terminologia correta, citando fontes e seguindo as regras de segurança definidas.

### 9.2 Por que LoRA (Low-Rank Adaptation)?

Retreinar completamente um modelo como GPT-2 (117M parâmetros) ou LLaMA (7B parâmetros) demandaria múltiplas GPUs de alto desempenho e dias de processamento. O LoRA resolve isso com uma abordagem elegante:

#### Como o LoRA funciona

Em vez de modificar os bilhões de parâmetros originais do modelo, o LoRA adiciona matrizes auxiliares de 'baixo posto' (low-rank) acopladas às camadas de atenção. Apenas essas matrizes são treinadas — representando menos de 1% do total de parâmetros. O resultado é um modelo especializado obtido em um menor tempo, mantendo todo o conhecimento geral do modelo base intacto.

### 9.3 Parâmetros LoRA utilizados e suas justificativas

| Parâmetro             | Valor e justificativa                                                                                                                                 |
|-----------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>r (rank)</b>       | 8 — Controla a capacidade das matrizes auxiliares. $r=8$ é o padrão para domínios especializados: suficiente para especialização sem overfitting.     |
| <b>lora_alpha</b>     | 32 — Fator de escala dos pesos LoRA. A razão $\alpha/r = 4$ é empiricamente eficaz para fine-tuning de domínio.                                       |
| <b>target_modules</b> | ['c_attn'] — Camada de atenção do GPT-2. Em modelos LLaMA usaria ['q_proj', 'v_proj']. A atenção é onde reside o 'conhecimento relacional' do modelo. |
| <b>lora_dropout</b>   | 0.05 — Regularização leve para evitar overfitting em datasets pequenos (<300 amostras).                                                               |
| <b>task_type</b>      | CAUSAL_LM — Modelagem de linguagem causal: o modelo aprende a prever o próximo token, padrão para modelos geradores de texto.                         |

## 9.4 Otimizações implementadas (e por que foram necessárias)

A versão original do código levaria aproximadamente 2 dias para executar no Google Colab. O notebook documenta explicitamente os problemas e as correções:

| Problema original                            | Otimização aplicada — resultado                                                                      |
|----------------------------------------------|------------------------------------------------------------------------------------------------------|
| <b>max_length=512 tokens por amostra</b>     | Reduzido para 256 — metade do computo sem perda relevante (respostas médicas cabem em ~200 palavras) |
| <b>Sem limite de amostras de treino</b>      | MAX_AMOSTRAS_TREINO = 80 (10 sintéticos + 70 PubMedQA) — suficiente para demonstrar fine-tuning      |
| <b>batch_size=2</b>                          | Aumentado para 4 com gradient_accumulation=4 — simula batch efetivo de 16 sem estourar VRAM          |
| <b>fp16=False (float32 sempre)</b>           | fp16 ativo somente quando há GPU (float32 em CPU) — 2x mais rápido na GPU T4 do Colab                |
| <b>3 épocas de treinamento</b>               | 1 época — suficiente para datasets pequenos (<300 amostras); epochs adicionais causariam overfitting |
| <b>Sem teto de passos</b>                    | max_steps=80 — teto absoluto de segurança para evitar treino infinito em datasets grandes            |
| <b>save_strategy='epoch' (3 checkpoints)</b> | save_strategy='no' — elimina I/O de checkpoints intermediários, economizando minutos                 |
| <b>Sem agrupamento por tamanho</b>           | group_by_length=True — agrupa amostras de tamanho similar, reduz padding desnecessário               |
| <b>dataloader_num_workers=0</b>              | dataloader_num_workers=2 — tokenização paralela, acelera carregamento dos dados                      |

### Tempo estimado após otimizações

GPU T4 (Colab gratuito): ~5–10 minutos. CPU apenas: ~20–30 minutos. Sem as otimizações: ~2 dias.

## 9.5 Modelo Base: por que GPT-2?

Em um protótipo acadêmico executado no Google Colab gratuito, o GPT-2 é a escolha pragmática: é leve (117M parâmetros), público, sem restrição de licença e executa em CPU ou GPU T4 sem problemas de memória. Em produção real, o notebook deixa explícito que simplesmente substituir 'gpt2' por 'meta-llama/Llama-2-7b-hf' ou 'tiiuae/falcon-7b' no código já utilizaria um modelo mais poderoso — a arquitetura do fine-tuning não muda.

## 10. CÉLULA 6B — AVALIAÇÃO QUANTITATIVA (ROUGE + BIAS)

Esta célula preenche a lacuna de métricas formais exigidas pelo desafio. Ela avalia o modelo em três dimensões complementares: qualidade textual das respostas, especialização no domínio médico, e equidade entre grupos demográficos de pacientes.

### 10.1 Métricas ROUGE

ROUGE (Recall-Oriented Understudy for Gisting Evaluation) é um conjunto de métricas padrão para avaliar modelos de geração de texto. Ela compara a sobreposição de n-gramas entre as respostas geradas e as respostas de referência:

| Métrica        | O que mede e threshold esperado                                                                                    |
|----------------|--------------------------------------------------------------------------------------------------------------------|
| <b>ROUGE-1</b> | Sobreposição de unigramas (palavras individuais) entre gerado e referência. $\geq 0.30$ indica cobertura razoável. |
| <b>ROUGE-2</b> | Sobreposição de bigramas (pares de palavras consecutivas). $\geq 0.10$ indica cobertura razoável de frases.        |
| <b>ROUGE-L</b> | Longest Common Subsequence — mede preservação de sequências longas de palavras. $\geq 0.20$ indica boa coerência.  |

### 10.2 Cobertura de Termos Médicos

Esta é uma métrica de domínio customizada para este trabalho — não existente em métricas padrão. Ela mede a proporção de termos clínicos especializados presentes nas respostas geradas, comparando com as respostas de referência. Termos avaliados incluem: ginecolog, obstetric, gestac, menstrua, anticoncepc, menopausa, papanicolau, mamografia, violencia, puerperio, entre outros em PT e EN.

### 10.3 Análise de Bias e Equidade Demográfica

O desafio exige explicitamente 'análise de bias e equidade entre grupos demográficos'. O código testa 4 dimensões críticas de potencial desigualdade nas respostas do modelo:

| Dimensão de bias testada       | Perfis avaliados e por que é importante                                                                                                                            |
|--------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Faixa etária</b>            | Adolescente (16a) vs. Adulta (35a) vs. Idosa (62a) — ciclo irregular. Verifica se o modelo adapta adequadamente suas sugestões à faixa etária.                     |
| <b>Contexto socioeconômico</b> | Baixa renda (SUS) vs. Renda média vs. Alta renda (plano). Garante que todas as pacientes recebam orientações equânimes e que o SUS não seja tratado como inferior. |

| Dimensão de bias testada         | Perfis avaliados e por que é importante                                                                                        |
|----------------------------------|--------------------------------------------------------------------------------------------------------------------------------|
| <b>Contexto geográfico</b>       | Zona rural (sem acesso a especialistas) vs. Zona urbana. Verifica se o modelo considera limitações de acesso na orientação.    |
| <b>Origem étnica (percebida)</b> | Indígena vs. Afrodescendente vs. Sem especificação — menopausa. Detecta se há diferenças sistemáticas no tratamento por etnia. |

O sistema avalia variação de comprimento e cobertura médica entre os perfis. Variação acima de 40% sinaliza risco de bias sistêmico que exigiria revisão do dataset de treinamento.

## 11. CÉLULA 7 — BASE DE CONHECIMENTO VETORIAL COM FAISS (RAG)

Esta célula implementa o componente RAG (Retrieval-Augmented Generation). O RAG é uma técnica que permite ao modelo de linguagem 'consultar' uma base de conhecimento externa antes de responder, tornando as respostas mais precisas e fundamentadas em fontes verificáveis.

### 11.1 O que é RAG e por que é superior ao fine-tuning sozinho?

O fine-tuning incorpora conhecimento nos pesos do modelo — mas o modelo pode 'esquecer' detalhes específicos ou alucinar informações. O RAG resolve isso buscando os documentos mais relevantes no momento da pergunta e passando-os como contexto ao LLM. As vantagens são: (1) a base de conhecimento pode ser atualizada sem retreinar o modelo; (2) as respostas são fundamentadas em documentos específicos e citáveis; (3) reduz drasticamente as alucinações do modelo.

### 11.2 Documentos de Protocolo incluídos na base

Seis documentos sintéticos baseados em diretrizes brasileiras e internacionais foram adicionados manualmente pelo desenvolvedor:

| Protocolo                          | Fonte e conteúdo principal                                                                                                             |
|------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------|
| <b>Triagem Ginecológica</b>        | FEBRASGO 2023 — classificação por cores (Verde/Amarela/Laranja/Vermelho), critérios diagnósticos para endometriose, SOP, DIP.          |
| <b>Violência Doméstica</b>         | Ministério da Saúde 2022 — notificação SINAN, medidas protetivas Lei Maria da Penha, profilaxia em violência sexual (<72h).            |
| <b>Pré-natal</b>                   | FEBRASGO/OMS 2023 — mínimo 6 consultas, exames por trimestre, vacinação obrigatória (dTpa, influenza), TOTG 24-28 semanas.             |
| <b>Rastreamento Câncer de Mama</b> | INCA 2023 — mamografia por faixa etária, critérios BI-RADS (0-6), indicação de biópsia para BI-RADS 4 e 5.                             |
| <b>Saúde Mental Materna</b>        | Literatura Psiquiatria Perinatal / MS Brasil — Escala Edinburgh (EPDS >= 10), fatores de risco DPP, psicose puerperal como emergência. |
| <b>Contracepção</b>                | FEBRASGO/ANVISA/Lei 9.263/1996 — métodos por eficácia, anticoncepção de emergência (levonorgestrel <72h, DIU cobre <120h).             |

### 11.3 Modelo de Embeddings: paraphrase-multilingual-MiniLM-L12-v2

O modelo sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2 foi escolhido por três razões complementares:

- Multilíngue — suporta português e inglês nativamente, essencial pois o dataset combina textos em ambos os idiomas (sintéticos PT + PubMedQA EN).
- Eficiente — modelo compacto (L12 = 12 camadas) que executa rapidamente mesmo em CPU, sem degradar significativamente a qualidade dos embeddings.
- Semântico — gera representações vetoriais que capturam significado (não apenas palavras), permitindo que uma busca por 'hematomas em paciente' recupere o documento de 'violência doméstica' mesmo que a palavra exata não esteja na query.

## 11.4 Como o FAISS funciona

O FAISS (Facebook AI Similarity Search) é uma biblioteca que cria um índice vetorial dos documentos. Quando o assistente recebe uma pergunta, o FAISS encontra os  $k=3$  documentos com maior similaridade cossenoidal ao vetor da pergunta — em milissegundos, independentemente do tamanho da base. Esses 3 documentos são passados como contexto ao LLM, que os usa para formular uma resposta fundamentada.

## 12. CÉLULA 8 — ASSISTENTE MÉDICO COM LANGCHAIN

Esta célula integra todos os componentes anteriores em uma única classe: `AssistenteMedicoFeminino`. É aqui que o `LangChain` atua como 'cola' entre o modelo fine-tuned, a base vetorial e as regras de segurança.

### 12.1 Arquitetura do Assistente — fluxo de uma consulta

#### FLUXO COMPLETO DE UMA CONSULTA — `AssistenteMedicoFeminino`

1. Profissional faz uma pergunta ao assistente
2. Detecção de sensibilidade — verifica se a pergunta menciona violência doméstica ou emergência de saúde mental
3. Se emergência de saúde mental → logging CRITICAL. Se violência doméstica → logging WARNING
4. Retriever FAISS busca os 3 documentos mais relevantes na base vetorial
5. Prompt estruturado é montado: [regras de segurança] + [contexto dos 3 documentos] + [pergunta]
6. LLM fine-tuned gera a resposta baseada no prompt completo (`chain_type='stuff'`)
7. Validação de segurança — verifica termos proibidos na resposta gerada
8. Se termo proibido detectado → adiciona aviso automático à resposta
9. Interação registrada no log de auditoria com hash, timestamp e fontes
10. Retorno estruturado: resposta + fontes + validação + timestamp + aviso legal

### 12.2 Configuração do LLM Local

O modelo fine-tuned é carregado via `hf_pipeline` (Hugging Face Pipeline) e encapsulado pelo `HuggingFacePipeline` do `LangChain`. Os parâmetros de geração são:

| Parâmetro de geração              | Valor e justificativa                                                                                                                         |
|-----------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------|
| <code>max_new_tokens = 300</code> | Limita o tamanho da resposta. 300 tokens ~ 250 palavras, suficiente para orientações clínicas sem ser excessivo.                              |
| <code>temperature = 0.3</code>    | Temperatura baixa = respostas mais determinísticas e precisas. Alta temperatura geraria variações criativas — indesejável em contexto médico. |
| <code>do_sample = True</code>     | Habilita amostragem probabilística (necessário quando <code>temperature &lt; 1.0</code> ). Sem isso, o modelo usa busca gulosa pura.          |



| Parâmetro de geração            | Valor e justificativa                                                                                                 |
|---------------------------------|-----------------------------------------------------------------------------------------------------------------------|
| <b>repetition_penalty = 1.2</b> | Penaliza a repetição de tokens já gerados, melhorando a fluidez e evitando que o modelo repita a mesma frase em loop. |
| <b>pad_token_id = 50256</b>     | Token de padding do GPT-2 (eos_token). Necessário para processar batches de tamanhos diferentes.                      |

## 12.3 Template de Prompt Especializado

O prompt define o comportamento do assistente de forma explícita. As regras de segurança inseridas no prompt correspondem exatamente aos requisitos do desafio:

```
REGRAS OBRIGATÓRIAS DE SEGURANÇA:
- NUNCA prescreva medicamentos sem validação de especialista
- NUNCA emita diagnóstico definitivo
- SEMPRE recomende consulta presencial para sintomas alarmantes
- SEMPRE encaminhe casos de violência doméstica para equipe especializada
- MANTENHA confidencialidade absoluta em casos sensíveis
- Use linguagem inclusiva, empática e culturalmente respeitosa

CONTEXTO DOS PROTOCOLOS:
{context} ← 3 documentos do FAISS inseridos aqui

PERGUNTA DO PROFISSIONAL:
{question} ← pergunta do usuário
```

## 12.4 Detecção de Sensibilidade

O método `_detectar_sensibilidade` verifica se a pergunta contém palavras associadas a casos sensíveis. O dicionário `CATEGORIAS_SENSIVEIS` mapeia palavras-gatilho para categorias: 'violencia', 'abuso', 'agressao' → `violencia_domestica`; 'suicidio', 'automutilacao' → `emergencia_saude_mental`. Casos de emergência de saúde mental geram log `CRITICAL`; violência doméstica gera log `WARNING`.

## 12.5 Validação de Respostas

Antes de retornar ao usuário, cada resposta é verificada contra uma lista de termos proibidos: 'prescrevo', 'diagnostico definitivo', 'voce tem', 'certamente e', 'pode tomar sem consultar'. Se qualquer um for detectado, um aviso de revisão por protocolo de segurança é automaticamente adicionado à resposta. Isso implementa a validação do LLM antes do retorno exigida pelo desafio.

## 13. CÉLULA 9 — FLUXOS DE TRIAGEM COM LANGGRAPH

O LangGraph permite criar grafos de estados onde cada nodo é uma função Python e as arestas representam transições entre etapas. Os quatro fluxos implementados correspondem diretamente aos quatro fluxos exigidos pelo desafio.

### 13.1 Estado Compartilhado — EstadoPaciente

Todos os fluxos compartilham o mesmo TypedDict EstadoPaciente, que funciona como uma 'ficha de atendimento digital' preenchida progressivamente a cada nodo do grafo:

| Campo do estado               | Significado e como é preenchido                                                                                      |
|-------------------------------|----------------------------------------------------------------------------------------------------------------------|
| <b>nome_anonimizado</b>       | Identificador da paciente sem dados pessoais (ex.: PAC_A3F9). Preenchido antes de invocar o fluxo.                   |
| <b>idade</b>                  | Idade da paciente em anos. Influencia sugestões de exames (Papanicolau >=25a, Mamografia >=40a).                     |
| <b>sintomas</b>               | Lista de sintomas relatados. O nodo de análise verifica quais sintomas críticos, altos ou moderados estão presentes. |
| <b>historico</b>              | Histórico clínico relevante (ex.: 'SOP diagnosticada', 'hipertensão'). Influencia classificação de risco.            |
| <b>nivel_risco</b>            | Classificação: 'critico', 'alto', 'moderado' ou 'baixo'. Preenchido pelo primeiro nodo de cada fluxo.                |
| <b>classificacao_urgencia</b> | Cor de urgência protocolo Manchester: VERMELHO/LARANJA/AMARELA/VERDE com tempo máximo de espera.                     |
| <b>exames_sugeridos</b>       | Lista de exames recomendados com base no risco e idade da paciente.                                                  |
| <b>encaminhamentos</b>        | Serviços ou especialistas para encaminhamento (DEAM, CREAS, ginecologista, psicologia etc.).                         |
| <b>alertas</b>                | Avisos críticos gerados pelo sistema (ex.: 'URGENTE: Sangramento — encaminhar à maternidade').                       |
| <b>orientacoes</b>            | Orientações ao profissional de saúde sobre como proceder.                                                            |
| <b>proximos_passos</b>        | Ações imediatas: agendamentos, envio de SMS, atualização de prontuário.                                              |
| <b>log_fluxo</b>              | Lista acumulativa de entradas com horário (HH:MM:SS) de cada nodo. Usa operator.add para acumulação automática.      |

## 13.2 Fluxo 1 — Triagem Ginecológica

### FLUXO 1 — TRIAGEM GINECOLÓGICA (5 nodos sequenciais)

1. `analisar_sintomas_ginecologicos` — classifica sintomas em crítico/alto/moderado/baixo (ex.: 'sangramento intenso' = crítico; 'ciclo irregular' = moderado)  
▼
2. `classificar_urgencia` — converte nível de risco em classificação de cor: VERMELHO (0-10min) / LARANJA (2h) / AMARELA (24h) / VERDE (eletiva)  
▼
3. `sugerir_exames_ginecologicos` — sugere exames por risco e idade: hemograma, USG, beta-hCG (alto/crítico); FSH/LH/TSH (ciclo irregular); Papanicolau  $\geq 25a$ ; Mamografia  $\geq 40a$   
▼
4. `gerar_orientacoes_ginecologicas` — orientações ao profissional: crítico → acionar plantonista; alto → contato ginecologista no dia; baixo → agendamento eletivo  
▼
5. `agendar_atendimento_ginecologico` — define prazo e próximos passos: imediato / 24h / 7 dias / 30 dias conforme risco

## 13.3 Fluxo 2 — Detecção de Violência Doméstica

### FLUXO 2 — DETECÇÃO DE VIOLÊNCIA DOMÉSTICA (3 nodos + sigilo)

1. `avaliar_sinais_violencia` — calcula score de risco: sinais diretos pesam 2 (lesões inexplicadas, hematomas, medo do parceiro); indiretos pesam 1 (IST de repetição, depressão, isolamento). Score  $\geq 4$  = crítico;  $\geq 2$  = alto;  $\geq 1$  = moderado  
▼
2. `aplicar_protocolo_seguranca` — crítico/alto: aciona DEAM, CREAS, Casa da Mulher, Assistência Social, Psicologia e (se crítico) SAMU. Moderado/baixo: acolhimento e contatos de apoio  
▼
3. `documentar_caso_violencia` — orienta: Ficha SINAN, prontuário restrito, fotografia com consentimento, armazenamento criptografado, sigilo absoluto, retorno seguro

## 13.4 Fluxo 3 — Avaliação Obstétrica

### FLUXO 3 — AVALIAÇÃO OBSTÉTRICA (2 nodos sequenciais)

1. `avaliar_risco_gestacional` — classifica como alto risco se: diabetes gestacional, hipertensão, pré-eclâmpsia, gêmeos, placenta prévia, histórico de aborto, sangramento, febre, ausência de

movimentos fetais, idade <17 ou >35 anos. Alertas específicos para sangramento e ausência de MF (emergências)



2. gerar\_plano\_prenatal — exames de rotina 1º trimestre para todas; exames adicionais para alto risco (TOTG, proteinúria, cardiotocografia, Doppler). Próximos passos: pré-natal de alto risco, sulfato ferroso + ácido fólico, orientação sinais de alerta

## 13.5 Fluxo 4 — Prevenção e Acompanhamento (com aresta condicional)

### FLUXO 4 — PREVENÇÃO E ACOMPANHAMENTO (aresta condicional)

1. identificar\_exames\_devidos — verifica por faixa etária: Papanicolau >=25a, Mamografia >=40a, Perfil lipídico >=45a, Densitometria >=50a, Glicemia >=60a, Vacina HPV <=45a (se não realizada). Identifica apenas exames NÃO registrados no histórico



2. ARESTA CONDICIONAL — se sem exames pendentes → 'sem\_pendencias'; se há pendências → 'com\_pendencias'. Ambos os caminhos passam por gerar\_orientacoes\_prev (garante que a paciente sempre receba orientação)



3. gerar\_orientacoes\_preventivas — sem pendências: mensagem de parabéns. Com pendências: solicitar exames, explicar importância, verificar acesso SUS; adiciona orientações de THM >=50a e cardiovascular >=60a



4. agendar\_preventivo — sem pendências: consulta preventiva em 12 meses. Com pendências: solicitar exames hoje, retorno 30 dias, lembrete SMS/app, registrar no prontuário, verificar programa Viva Mulher SUS

### Diferencial do Fluxo 4: Aresta Condicional

O Fluxo 4 é o único que utiliza `add_conditional_edges` do LangGraph — uma aresta que decide o próximo nodo com base no estado atual. A função `decidir_continuidade_prevencao` verifica se há exames pendentes para direcionar o fluxo de forma inteligente. Isso demonstra o uso avançado do LangGraph além de grafos puramente sequenciais.

## 14. SEGURANÇA, VALIDAÇÃO E AUDITORIA

O desafio dedica uma seção inteira a segurança e validação. O trabalho implementa múltiplas camadas de proteção, correspondendo a cada requisito.

### 14.1 Limites de Atuação — Hard Rules

As seguintes regras são implementadas como verificações ativas no código, não apenas como instruções no prompt:

| Regra do desafio                             | Implementação técnica no código                                                                         |
|----------------------------------------------|---------------------------------------------------------------------------------------------------------|
| <b>NUNCA prescrever medicações</b>           | Detecção de 'prescrevo' na resposta → aviso automático + log WARNING                                    |
| <b>NUNCA diagnosticar definitivamente</b>    | Detecção de 'diagnóstico definitivo', 'você tem', 'certamente é' → aviso + log                          |
| <b>SEMPRE encaminhar violência doméstica</b> | Detecção de palavras-gatilho → Fluxo 2 LangGraph com acionamento da rede de proteção                    |
| <b>SEMPRE recomendar consulta presencial</b> | Incluso em cada resposta do dataset sintético e no template do prompt                                   |
| <b>MANTER confidencialidade em violência</b> | Logs de violência em nível WARNING separado; documentação em prontuário restrito orientada pelo Fluxo 2 |

### 14.2 Logging e Auditoria

O sistema de logging configurado na Célula 2 registra todos os eventos relevantes durante a execução:

- INFO — cada interação normal com o assistente (hash da pergunta + fontes utilizadas)
- WARNING — detecção de possível violência doméstica
- CRITICAL — detecção de emergência de saúde mental (suicídio, automutilação)
- ERROR — falhas na geração de resposta pelo LLM

O método `gerar_relatorio_auditoria()` da classe `AssistenteMedicoFeminino` permite gerar um `DataFrame` pandas com todas as interações registradas — atendendo ao requisito de 'relatórios de utilização por especialidade médica' do desafio.

### 14.3 Explainability

Cada resposta retornada pelo assistente inclui o campo 'fontes' — uma lista dos documentos recuperados pelo FAISS que embasaram a resposta, com o nome da fonte (ex.:

'FEBRASGO 2023'), a categoria e um preview do conteúdo. Isso atende ao critério de explainability do desafio: 'indicar fonte específica da informação' e 'mostrar nível de confiança nas sugestões'.

#### **Aviso Legal em todas as respostas**

Todas as respostas do assistente incluem o campo 'aviso\_legal': 'Este assistente é ferramenta de apoio clínico. Não substitui avaliação médica presencial.' Este aviso é parte da resposta estruturada e não pode ser removido pelo usuário final.

## 15. INTEGRAÇÃO COMPLETA — COMO OS COMPONENTES SE CONECTAM

Este é o ponto mais importante para entender o trabalho como um todo: como os quatro componentes (fine-tuning, RAG, LangChain e LangGraph) se integram em uma solução coesa.

### 15.1 Dois modos de operação do sistema

O sistema pode ser usado de duas formas complementares:

#### Modo 1 — Consulta ao Assistente (LangChain + RAG)

Um profissional faz uma pergunta aberta ao assistente. O LangChain orquestra: retriever FAISS busca documentos relevantes, o LLM fine-tuned gera a resposta baseada no contexto recuperado. Ideal para dúvidas clínicas, consultas sobre protocolos, orientações gerais. Exemplo: 'Quais são os sinais de alerta na gravidez?'

#### Modo 2 — Triagem Estruturada (LangGraph)

O profissional entra com dados estruturados de uma paciente (idade, sintomas, histórico). O grafo LangGraph percorre cada nodo do fluxo correspondente, preenchendo progressivamente o estado da paciente até gerar: nível de risco, classificação de urgência, exames sugeridos, encaminhamentos e próximos passos. Ideal para triagem padronizada e rastreável. Exemplo: Fluxo Ginecológico com paciente de 35 anos com dor pélvica crônica.

### 15.2 Fluxo de dados ponta a ponta

| Dado de entrada                                | Percurso no sistema e saída                                                                                     |
|------------------------------------------------|-----------------------------------------------------------------------------------------------------------------|
| Arquivo JSON PubMedQA (1.000 registros)        | Célula 3: filtro → ~270 registros relevantes → Célula 4: combinação com sintéticos → df_treino (~280 registros) |
| df_treino (~280 registros)                     | Célula 5: anonimização + normalização + template Alpaca → df_processado com coluna texto_fine_tuning            |
| df_processado (coluna texto_fine_tuning)       | Célula 6: tokenização → fine-tuning LoRA → modelo salvo em ./modelo_saude_mulher_final                          |
| 6 documentos de protocolo + registros PubMedQA | Célula 7: embeddings MiniLM → índice FAISS → salvo em ./base_vetorial_saude_mulher                              |
| modelo fine-tuned + índice FAISS               | Célula 8: HuggingFacePipeline + FAISS retriever → classe AssistenteMedicoFeminino                               |

| Dado de entrada                                       | Percurso no sistema e saída                                                                                           |
|-------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------|
| Pergunta do profissional (string)                     | Assistente: detecção sensibilidade → recuperação FAISS → prompt montado → LLM gera → validação → log → dict retornado |
| Dados da paciente (dict com idade/sintomas/histórico) | LangGraph: fluxo adequado → nodos preenchem estado → dict final com risco/exames/orientações/log                      |



## 16. CONSIDERAÇÕES ÉTICAS E REGULATÓRIAS

---

### 16.1 LGPD — Lei Geral de Proteção de Dados

O trabalho implementa instrumentos de aderência à LGPD em múltiplas camadas: anonimização de dados pessoais no pré-processamento (Célula 5), hash SHA-256 para rastreabilidade sem expor conteúdo, logs sem dados pessoais identificáveis (apenas hashes), e orientação no Fluxo 2 para armazenamento criptografado de dados de violência doméstica.

### 16.2 Assistente como Ferramenta de Apoio, não Substituto

Este é o princípio mais importante do trabalho: o assistente é explicitamente posicionado como ferramenta de apoio à decisão clínica, nunca como substituto do profissional de saúde. Isso se manifesta tecnicamente em: aviso legal em todas as respostas, regras proibindo diagnósticos definitivos e prescrições, sempre recomendando consulta presencial em sintomas alarmantes, e o disclaimer no início do notebook.

### 16.3 Sensibilidade Cultural e Equidade

A análise de bias (Célula 6b) verifica se o modelo trata pacientes de diferentes origens étnicas, faixas de renda e contextos geográficos de forma equânime. O template de prompt instrui explicitamente o modelo a usar 'linguagem inclusiva, empática e culturalmente respeitosa'. Os dados sintéticos incluem casos de pacientes indígenas, afrodescendentes, de zona rural e de baixa renda.

### 16.4 Protocolo específico para violência doméstica

O Fluxo 2 implementa o protocolo do Ministério da Saúde para violência contra a mulher: notificação compulsória via Ficha SINAN, acionamento da rede de proteção (DEAM, CREAS, Casa da Mulher Brasileira), documentação segura com sigilo absoluto, e profilaxia de IST/anticoncepção de emergência nas primeiras 72 horas. Esses elementos são baseados na Lei 11.340/2006 (Lei Maria da Penha) e nas normativas do Ministério da Saúde.

#### **Declaração de Escopo Acadêmico**

Este sistema é um protótipo acadêmico desenvolvido para a disciplina de pós-graduação POSTECH — IA para DEVs, Fase 3. Não deve ser utilizado em ambiente clínico real sem validação por especialistas em ginecologia e obstetrícia, adequação às normas do CFM, auditoria de segurança, e homologação pelo sistema hospitalar. Todas as orientações geradas são de apoio à decisão e não substituem a avaliação presencial por profissional habilitado.

— *Fim da Documentação Técnica* —

FIAP